



Oberschulzentrum J. Ph. Fallmerayer Brixen

Technologische Fachoberschule (TFO)
Fachrichtung Informatik und Telekommunikation
Schwerpunkt Informatik

Paralleles Programmierparadigma

Abschlussarbeit am Ende der Oberschule
Facharbeit aus Technologien und Planung von informatischen Systemen
und Telekommunikationssystemen (TP)
Schuljahr 2017/18

Thomas Mittermair
Klasse 5BT

Betreut von
Prof. Alexander Larcher

Brixen, Italien,
am 30. März 2018

Abstract

Hier kommt der Abstract.

Inhaltsverzeichnis

1	Einleitung und Motivation	1
1.1	Einführung in die Problematik der Parallelisierung	1
1.1.1	Begriffe der Sequentialität und Parallelität	1
1.2	Gründe für das parallele Programmierparadigma	4
1.2.1	Möglichkeiten der Leistungserhöhung	5
1.2.2	Moore'sches Gesetz	5
1.2.3	Trends im Hochleistungsrechnen	6
2	Theoretische Grundbegriffe und Konzepte	9
2.1	Grundprinzipien der Parallelisierung	9
2.1.1	Teile und herrsche (divide and conquer, divide et impera)	9
2.1.2	Fork-Join-Modell	10
2.1.3	Lastenverteilung (load balancing)	11
2.1.4	Parallelität und Nebenläufigkeit	11
2.2	Implementierungsmöglichkeiten der Parallelisierung	12
2.2.1	Implementierungsmöglichkeiten der Parallelisierung auf Hardwareebene	12
2.2.2	Implementierungsmöglichkeiten der Parallelisierung auf Softwareebene	14
2.3	Prozess-Synchronisation [1]	23
2.3.1	Probleme bei der parallelen Bearbeitung	24
2.3.2	Lösungen zu den Problemen der parallelen Verar- beitung	35
	Literaturverzeichnis	41

Kapitel 1

Einleitung und Motivation

1.1 Einführung in die Problematik der Parallelisierung

Der Begriff der *Parallelität* existiert nicht nur im Bereich der Informatik, sondern vor allem im Alltag und in der Natur ist selbiger oft vorzufinden und somit allgegenwärtig. Um zu begreifen, worum es sich bei Parallelität handelt, muss zunächst klargestellt werden, worin der Unterschied zwischen Sequentialität und Parallelität liegt.

1.1.1 Begriffe der Sequentialität und Parallelität

Sequentialität Der Begriff *Sequentialität* hängt eng mit dem Adjektiv *sequenziell* zusammen. Vorgänge, die sequenziell ablaufen, spielen sich aufeinander folgend und der Reihe nach ab. [2]

Parallelität Der Begriff *Parallelität* hängt eng mit dem Adjektiv *parallel* zusammen. Vorgänge, die parallel ablaufen, spielen sich gleichzeitig und synchron ab. [3]

1.1.1.1 Sequentialität und Parallelität im Alltag und in der Natur

Jeder Mensch ist, oft ohne davon Kenntnis zu nehmen, täglich mit sequentiellen und parallelen Vorgängen und Abläufen konfrontiert. Ein alltägliches Beispiel für Sequentialität ist der Begriff von Zeit, denn eine Sekunde vergeht erst, sobald die vorherige Sekunde vollkommen abgelaufen ist. Zeit läuft somit vollkommen sequentiell ab, wodurch das Kausalitäts-Prinzip, also das Prinzip von Ursache und Wirkung, erst möglich wird, denn hätte die Zeit diese Eigenschaft nicht, so wären Ursache und Wirkung nicht klar voneinander unterscheidbar. Folglich geschieht in der Natur nichts ohne Grund, und das bedeutet wiederum, dass es zu jedem

beliebigen Ereignis ein anderes Ereignis gibt, dass in der Vergangenheit liegt und das nachfolgende Ereignis hervorruft. [4] Viele Vorgänge in der Natur laufen hingegen parallel ab. Beispielsweise findet stets eine simultane Weiterentwicklung statt, denn jeder Mensch und auch jede Pflanze entwickeln sich gleichzeitig, und nicht nacheinander, weiter. [5]

1.1.1.2 Sequentialität und Parallelität in der Informatik

Die Informatik ist eine Wissenschaft, die in vielen Bereichen das Ziel verfolgt, Objekte und auch Abläufe der realen Welt auf Ebene von Rechnern möglichst realitätsgetreu nachzubilden. Ein informatisches Modell der Wirklichkeit soll folglich so nahe wie möglich an die zu modellierende Begebenheit herankommen. Ein in diesem Zusammenhang oft genanntes Beispiel ist das objektorientierte Programmierparadigma. Dabei werden Objekte der realen Welt durch Datenstrukturen im Computer nachgeahmt. Dies erlaubt es, Sachverhalte in der Realität nahezu direkt und ohne große Abänderungen in einer objektorientierten Programmiersprache zu modellieren. [6] Ähnliches gilt für die Sequentialität und Parallelität in der Informatik. Um zu verstehen, wie diese beiden Gegensätze in der Informatik zusammenhängen und realisiert werden, muss zunächst erläutert werden, wie ein Prozessor Befehle abarbeitet.

Ausführungsschema eines Prozessors Der Prozessor, auch CPU (Central Processing Unit) genannt, ist das Herzstück eines Rechners. Er ist die Komponente, welche für die Ausführung und Abarbeitung der Befehle zuständig ist. Ein Prozessor kann dabei im Normalfall, also sofern er nur aus einem Kern besteht, nur eine Operation zugleich ausführen. Diese Eigenschaft leitet sich vom Schema ab, nach welchem die Mehrheit aller im Moment auf dem Markt befindlichen CPUs arbeiten. Dabei handelt es sich um den *Von-Neumann-Zyklus*, allgemeiner auch als *Befehlszyklus* bekannt. Die Abarbeitung eines Befehls geschieht dabei nach dem folgenden Schema:

1. **Instruction-Fetch-Phase (IF), Befehlholungs-Phase:** In dieser Phase wird der Befehlscode vom Hauptspeicher in ein Register des Prozessors geladen.
2. **Instruction-Decode-Phase (ID), Befehldekodierungs-Phase:** Der in ein Register geladene Befehl wird nun decodiert, um den Befehl weiterverarbeiten zu können. In dieser Phase wird der Befehl folglich analysiert, um Informationen zur Art des Befehls sowie zu Art und Anzahl der beteiligten Operanden und weitere Details zu ermitteln.
3. **Fetch-Operands-Phase (FO), Operandennachladungs-Phase:** In dieser Phase werden die Operanden, welche zur

Befehl 1	IF	ID	FO	EX	WB										
Befehl 2						IF	ID	FO	EX	WB					
Befehl 3											IF	ID	FO	EX	WB
Zeitpunkt	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15

Abbildung 1.1: Grafische Darstellung der Abarbeitung von drei Befehlen nach dem Schema des Befehlszyklus.

Abarbeitung des Befehls notwendig sind, in die Register nachladen. Bei Befehlen ohne Operanden bleibt diese Phase leer, da sie in diesem Fall nicht benötigt wird. Die Fetch-Operands-Phase kann auch als Unterphase der Instruction-Decode-Phase betrachtet werden, da die Operanden, welche in der Instruction-Decode-Phase ermittelt wurden, in dieser Phase aus dem Hauptspeicher in die Register geladen werden.

4. **Execute-Phase (EX), Befehlausführungs-Phase:** In dieser Phase kann der Befehl nun, beispielsweise unter Verwendung des Rechenwerkes, ausgeführt werden. Hierbei wird der geladene Befehl unter Verwendung der geladenen Operanden (falls vorhanden) abgearbeitet.
5. **Write-Back-Phase (WB), Resultat-Rückschreibungs-Phase:** In dieser Phase werden die Ergebnisse aus der Execute-Phase in den Speicher (z.B. in ein anderes Register oder auch in einen externen Speicher) zurückgeschrieben. Bei Befehlen ohne Resultat bleibt diese Phase leer, da sie nicht benötigt wird.

Jeder einzelne Befehl durchläuft dieses Schema, das bedeutet, nachdem ein Befehl die Write-Back-Phase abgeschlossen hat, kann der nächste Befehl mit der Instruction-Fetch-Phase beginnen. [7] [8]

Diese Sequentialität des Befehlszyklus soll nun an Hand eines Beispiels der Abarbeitung von drei Befehlen verdeutlicht werden. Die Abbildung Grafische Darstellung der Abarbeitung von drei Befehlen nach dem Schema des Befehlszyklus soll diesen Vorgang grafisch veranschaulichen.

Für eine geraume Zeit in der Geschichte der Rechner war die sequentielle Abarbeitung auch die einzig Mögliche. Bei der Modellierung von Abläufen der Realität, die aus parallelen Vorgängen bestehen, führt die Sequentialisierung zu einer künstlichen Einschränkung, da parallel ablaufende Vorgänge in einem hochwertigen Modell auch parallel ablaufen müssen. Um eine bessere Modellierung von parallelen Vorgängen zu ermöglichen, musste folglich ein neues Programmierparadigma definiert

werden, welches die Parallelität berücksichtigt. Selbiges ist heute unter dem Namen *Paradigma der Parallelen Programmierung* oder auch *Paralleles Programmierparadigma* bekannt und wird oft eingesetzt. Dieses Paradigma erlaubt es, Parallelverarbeitung auf Ebene der Informatik zu realisieren. Wie und mit welchen Konzepten dies geschieht bzw. geschehen kann, soll im Verlauf dieser Arbeit klar werden.

1.2 Gründe für das parallele Programmierparadigma

Neben der besseren Modellierung von parallelen Vorgängen bietet die Parallelisierung noch einige weitere Vorteile. Schon seit einigen Jahren wird die parallele Programmierung im Bereich des Hochleistungs-Rechnens verwendet. Genauere Simulationen oder auch die Simulationen von komplexeren Problemen benötigt immer mehr Rechenleistung und auch Speicherplatz. Ein oft genanntes Beispiel sind in diesem Zusammenhang die Wetter-Simulationen, welche auf komplizierten mathematischen Modellen basieren. Das Vorhersagen der zukünftigen Entwicklung der Atmosphäre ist nur durch die Verwendung eines Modells und einer daraus resultierenden Simulation möglich. Die Schwierigkeit bei Computersimulationen liegt allerdings darin, dass sie meist einen großen Rechenaufwand nach sich ziehen. Ein nicht leistungsfähiger Rechner kann die Simulation selbst oder auch die Genauigkeit des resultierenden Ergebnisses erheblich einschränken. Aus diesem Grund werden Parallelrechner¹ oft im Zusammenhang mit Computersimulationen verwendet. Um solche Rechner ausnutzen zu können, muss die durchzuführende Berechnung in mehrere, kleinere Teile zerlegt werden, welche dann den einzelnen, parallelen Abarbeitungseinheiten zugeordnet werden können. Diese einzelnen Berechnungen sollten unabhängig voneinander ablaufen, und auch der Algorithmus, der angewendet wird, muss in parallel ausführbare Einheiten zerlegbar sein. Um eine parallele Ausführung zu ermöglichen, muss der Algorithmus allerdings in einer Programmiersprache verfasst werden, welche entweder die Parallelisierung direkt, durch Hinzunahme von externen Bibliotheken oder auch durch spezielle Compiler-Direktiven unterstützt, welche zu einer gewöhnlichen Programmiersprache wie beispielsweise C oder Java hinzugefügt werden. [9]

¹Ein Parallelrechner ist ein Rechner, der über mehrere Ausführungseinheiten (z.B. Kerne oder Prozessoren) verfügt und somit echte Parallelverarbeitung unterstützt.

1.2.1 Möglichkeiten der Leistungserhöhung

Eine erhöhte Rechenleistung kann allerdings nicht nur durch Parallelisierung erreicht werden kann. Da die CPU, wie bereits erwähnt, Befehle im einfachsten Fall nur sequentiell abarbeiten kann, eröffnen sich intuitiv zwei Möglichkeiten der Leistungssteigerung:

1. Die erste Variante der Erhöhung der Performance besteht in der Beschleunigung der Abarbeitungszeit, die der Prozessor für einen Befehl benötigt. Dieser Lösungsansatz wirkt zunächst passend, da die Prozessoren immer kleiner und billiger werden. Doch diese Entwicklung zu immer kleineren, leistungsfähigeren CPUs ist gewissen physikalische Begrenzungen, wie beispielsweise der Lichtgeschwindigkeit als natürliche obere Grenze der Signalübertragungsgeschwindigkeit, unterworfen. Das Erreichen von Fortschritten bei der Erhöhung der Einprozessorleistung wird folglich immer schwieriger. [10]
2. Angesichts des obigen Problems rücken die Fortschritte in der Netzwerktechnik in den Vordergrund. Die Verbindungen zwischen Rechnern werden immer besser, die Geschwindigkeiten höher und die Bandbreiten größer. Somit wird es in Zukunft einfacher, mehrere Prozessoren miteinander zu verbinden, sodass sie parallel an einem gemeinsamen Problem arbeiten, als die Leistung der einzelnen Komponenten zu erhöhen. [10] Solche sogenannte Parallelrechner sind folglich die Zukunft des Hochleistungsrechnens.

1.2.2 Mooresches Gesetz

Einer der Mitbegründer von Intel, Gordon Moore, formulierte im Jahr 1965 das nach ihm benannte Mooresche Gesetz. Dieses besagt, dass sich die Anzahl der Transistoren, welche in einem Prozessor enthalten sind, alle 18 Monate verdoppelt. Diese Aussage traf Moore in Bezug auf die sich damals schnell entwickelnde Halbleiter-Industrie. Zehn Jahre später, im Jahr 1975, relativierte er die von ihm formulierte Regel, in dem er die Verdopplung der Anzahl der Transistoren in einem Chip von nun an auf in etwa alle zwei Jahre voraussagte. In diesem Zusammenhang muss allerdings erwähnt werden, dass dieses Gesetz auf Empirie² basiert, und folglich für die Wissenschaft genau genommen keinerlei Bedeutung hat. Im Jahr 2003 hielt Moore einen Vortrag über die Zukunft der Halbleiterbranche an der *International Solid-State Circuits Conference (ISSCC)*, während welchem er sich eingestand, dass das nach ihm benannte Gesetz wohl in den nächsten Jahren seine Gültigkeit verlieren würde. [12] Schenkt man Moore und den Gesetzen der Physik Glauben, so wird die

²Empirie bezeichnet auf Basis von Erfahrung gewonnenes Wissen. [11]




Abbildung 1.2: Zusammenhang zwischen der Anzahl der Transistoren in einem Prozessor und dem Mooreschen Gesetz.

zweite der unter Möglichkeiten der Leistungserhöhung genannten Möglichkeit die Zukunft der Informatik bestimmen. Die Abbildung Abbildung 1.2 verdeutlicht nochmals den Zusammenhang zwischen der historischen Entwicklung der Anzahl der Transistoren auf einem Prozessor und dem Mooreschen Gesetz. Dabei sei erwähnt, dass die Skalierung der y-Achse dieses Graphes keineswegs linear ist, sondern logarithmisch erfolgt.

1.2.3 Trends im Hochleistungsrechnen

Auch im Bereich des Hochleistungsrechnens werden zunehmend immer mehr Prozessoren verbunden, anstatt wenige leistungsstarke CPUs zu verwenden. Die großen Rechenzentren, wie beispielsweise das Leibniz-Rechenzentrum der Bayrischen Akademie der Wissenschaften (LRZ), verwenden sogenannte Super-Computer, welche aus tausenden von Prozessoren bestehen. Das LRZ ist beispielsweise im Besitz eines Rechners mit dem Namen *SuperMUC*, welcher sich in der Nähe der deutschen Großstadt München befindet. Dieser besteht aus mehr als 241.000 Prozessor-Kernen und erreicht eine Spitzenleistung von mehr als 6,8 Pe-

taflop/s, also mehr als $6,8 \cdot 10^{15}$ Floating Point Operations Per Second (Gleitkommazahl-Operationen pro Sekunde). Damit ist selbiger einer der aktuell schnellsten Super-Computer. [13]

Somit wird klar, dass das parallele Programmierparadigma in Zukunft wohl noch an Bedeutung gewinnen wird und sich eine Auseinandersetzung mit diesem mittlerweile breitgefächerten Gebiet der Informatik lohnt.

Kapitel 2

Theoretische Grundbegriffe und Konzepte

2.1 Grundprinzipien der Parallelisierung

Bei der Parallelisierung, also der Aufteilung eines Vorgangs in verschiedene, meist voneinander unabhängige Abarbeitungsstränge, existieren einige Grundprinzipien, die beachtet werden müssen und aus diesem Grund im Folgenden näher erläutert werden.

2.1.1 Teile und herrsche (divide and conquer, divide et impera)

In der Informatik wird man oft mit Problemen konfrontiert, die als Ganzes betrachtet zunächst nur schwer bewältigbar erscheinen. Aus diesem Grund wurde eine Strategie mit dem Namen *teile und herrsche*, auch *divide and conquer* oder *divide et impera* genannt, entwickelt. Selbige ist für viele Bereiche der Informatik unabdingbar. Dabei wird ein Problem so lange in kleiner Teilprobleme zerlegt, bis sich die entstehenden Teilprobleme einfach lösen lassen. Diese Teillösungen müssen im Anschluss noch zu einer Gesamtlösung kombiniert werden. Diese Vorgehensweise erleichtert oft das Lösen komplexer Probleme, aber auch einfache Sachverhalte können durch die Anwendung dieser Strategie meist eleganter und schneller gelöst werden. [14]

Beispielweise funktioniert der Sortier-Algorithmus *Mergesort* nach diesem Prinzip. Das zu lösende Problem besteht in der Sortierung einer zugeordneten Liste von Einträgen gemäß ihres Schlüssels. Dabei wird die Liste rekursiv in kleinere Teillisten aufgeteilt, bis nur noch Listen übrig bleiben, die aus einem Element bestehen. Listen mit nur einem Element gelten als sortiert. Nun müssen diese Teillösungen noch zu einer Gesamtlösung kombiniert werden. Dabei werden die entstandenen Teilli-

sten wieder zu größeren, aber sortierten Listen zusammengefügt, bis nur noch eine Liste übrig bleibt. Die Liste gilt dann als sortiert. [15]
Somit wird klar, dass auch die parallele Programmierung nach dem Prinzip *teile und herrsche* arbeitet. Ein Problem wird hierbei in verschiedenen Teilprobleme aufgeteilt, welche dann parallel abgearbeitet werden können. Dabei muss allerdings beachtet werden, ob Parallelverarbeitung möglich ist, denn nicht jedes Problem ist parallelisierbar. Wenn beispielsweise ein Aufgabe aus Teilaufgaben besteht, die jeweils alle vom Ergebnis der vorhergehenden Teilaufgabe abhängen, so ist durch die Parallelisierung keine Leistungssteigerung möglich. In diesem Fall würden die eigentlich für parallele Arbeit ausgelegten Komponenten nacheinander am Problem arbeiten, was dem Prinzip der Leistungssteigerung vollkommen widerspricht.

2.1.2 Fork-Join-Modell

Das Fork-Join-Modell ist ein grundlegendes Prinzip im Bereich der Parallelisierung. Das englische Verb *to fork* kann dabei mit *gabeln* oder auch *aufspalten* übersetzt werden, das englische Verb *to join* hingegen mit *verbinden* oder auch *zusammenströmen*. Verwendet man dieses Konzept, so existiert in einem Programm zunächst ein Abarbeitungsstrang, der sequentiell Befehle abarbeitet. Kommt das auszuführende Programm zum Punkt, an welchem eine Parallelverarbeitung möglich wird, erstellt dieser Haupt-Abarbeitungsstrang n Kind-Abarbeitungsstränge, welche dann parallel an einem Problem arbeiten. Diese Gabelung des sequentiellen Haupt-Abarbeitungsstranges in mehrere Kind-Abarbeitungsstränge entspricht dem *Fork*. Während die Kind-Abarbeitungsstränge am Problem arbeiten, kann der Haupt-Abarbeitungsstrang, welcher in diesem Zusammenhang auch Eltern- oder Vater-Abarbeitungsstrang genannt wird, entweder auch an der Lösung des Problems mitarbeiten oder auch andere Aufgaben erledigen und muss dann auf die Terminierung der Kind-Abarbeitungsstränge warten. Das Zusammenströmen des Haupt-Abarbeitungsstranges mit den n Kind-Abarbeitungssträngen entspricht dem *Join*, da aus mehreren parallelen Abarbeitungssträngen wieder ein einziger, sequentieller Abarbeitungsstrang wird.

Das Fork-Join-Modell weist den Vorteil auf, dass es eine einfache Erstellung parallel arbeitender Programme ermöglicht. [9] Aus der Beschreibung dieses Modells lässt sich leicht erkennen, dass das Fork-Join-Modell auf dem Prinzip des unter Punkt Teile und herrsche (divide and conquer, divide et impera) erwähnten Prinzips *teile und herrsche* aufbaut.

2.1.3 Lastenverteilung (load balancing)

Die konsequente Anwendung des unter Punkt Fork-Join-Modell genannten *Fork-Join-Modells* führt zu einer grundlegenden Frage, welcher parallele Handlungsstrang wie viel Arbeit leisten soll und wie die gesamte Arbeit (Last) aufgeteilt werden soll.

Das Hauptziel der Zuweisung der Arbeit an die jeweiligen parallelen Handlungsstränge sollte sein, dass eine hochwertige *Lastenverteilung*, auch *load balancing* genannt, daraus resultiert, das bedeutet, jeder parallele Handlungsstrang sollte, sofern möglich, die gleiche Menge an Berechnung durchführen müssen. [9] Der Grund, warum jeder parallele Handlungsstrang gleich viel Last tragen, also gleich viel Arbeit verrichten sollte, liegt in der Natur des Fork-Join-Modells. Da der Haupt-Abarbeitungsstrang auf die Terminierung *aller* Kind-Abarbeitungsstränge warten muss, ist die parallele Lösung des Problems nur performant, falls alle parallelen Abarbeitungsstränge annähernd gleich viel Zeit für die Abarbeitung benötigen. Das folgende Sprichwort beschreibt diesen Sachverhalt angemessen:

Eine Kette ist nur so stark wie ihr schwächstes Glied. [16]

Überträgt man das obige Sprichwort auf die Parallelisierung, so wird aus der Stärke der Kette die Ausführungsgeschwindigkeit des parallelen Teils des Programmes und aus den einzelnen Gliedern der Kette werden die einzelnen, parallelen Abarbeitungsstränge im Programm. Das Ziel der Lastenverteilung ist es folglich, die Last so auf die parallelen Abarbeitungsstränge aufzuteilen, dass die geringste Gesamtausführungszeit des Programms daraus resultiert. Das gleichmäßige Aufteilen der Arbeit ist somit das Bestreben dieses grundlegenden Konzepts der parallelen Programmierung.

2.1.4 Parallelität und Nebenläufigkeit

Im Bereich der Parallelisierung stößt man des Öfteren auf zwei Begriffe, nämlich dem Begriff der *Nebenläufigkeit* und dem der *Parallelität*, welche im Folgenden näher erläutert werden.

Nebenläufigkeit Zwei Vorgänge nennt man *nebenläufig*, wenn sie vollkommen voneinander unabhängig abgearbeitet werden können. Existieren zwei nebenläufige Vorgänge A und B, so spielt es keine Rolle, ob zuerst Vorgang A und dann Vorgang B abgearbeitet wird oder umgekehrt, oder ob sie sogar gleichzeitig, also parallel, erledigt werden.

Anweisungen, welche nebenläufig sind, können also parallel und auch auf verschiedenen Prozessoren ausgeführt werden. Werden

sie auf einem Prozessor ausgeführt, so kann der Prozessor beliebig zwischen der Abarbeitung des Vorganges A und B hin und her wechseln und die Abarbeitungsreihenfolge ist somit nicht von Bedeutung.

Parallelität Zwei Vorgänge nennt man *parallel*, wenn sie gleichzeitig und unabhängig voneinander abgearbeitet werden können. Die Anweisungen zweier Vorgänge werden also parallel bearbeitet, wenn die Anweisungen unabhängig voneinander zur selben Zeit erledigt werden. Eine parallele Bearbeitung ist somit immer auch nebenläufig.

Somit wird klar, dass *Nebenläufigkeit* ein allgemeinerer Begriff als *Parallelität* ist. [17]

Quellen (zitieren ist schwierig, muss noch eine Lösung gefunden werden):

<http://ddi.cs.uni-potsdam.de/HyFISCH/Produzieren/SeminarDidaktik/Nebenlaeufigkeit/nebenlaeufig.h>

<https://www-vs.informatik.uni-ulm.de/teach/ss03/ti1/2003s-TI1-H-Proc-2-D.pdf>

2.2 Implementierungsmöglichkeiten der Parallelisierung

Die Parallelisierung kann auf verschiedensten Arten realisiert werden. Im Allgemeinen lassen sich allerdings zwei Ebenen erkennen: Die Hardware- und Softwareebene.

2.2.1 Implementierungsmöglichkeiten der Parallelisierung auf Hardwareebene

Auf Ebene der Hardware gibt es eine Vielzahl von Möglichkeiten, eine Parallelisierung zu implementieren. Im Folgenden werden dabei exemplarisch zwei grundlegende Varianten erläutert.

2.2.1.1 Pipelining

Wie aus Punkt Sequentialität und Parallelität in der Informatik ersichtlich wird, erfolgt die Abarbeitung eines Befehls in einem Prozessor wie an einem Fließband (engl. Pipeline), der Befehl durchläuft also mehrere, in diesem Fall fünf, Stufen. Zunächst wird der Befehl geladen, dann dekodiert, danach werden die Operanden geladen, der Befehl ausgeführt und das Ergebnis schließlich in den Speicher zurückgeschrieben.

Betrachtet man erneut die Abbildung zum Befehlszyklus Grafische Darstellung der Abarbeitung von drei Befehlen nach dem Schema des Befehlszyklus, so erkennt man, dass die Hardware bei dieser Art der Befehlsausführung nicht effizient ausgenutzt wird. Betrachtet man die fünf

Befehl 1	IF	ID	FO	EX	WB			
Befehl 2		IF	ID	FO	EX	WB		
Befehl 3				IF	ID	FO	EX	WB
Zeitpunkt	1	2	3	4	5	6	7	8

Abbildung 2.1: Grafische Darstellung der Abarbeitung von drei Befehlen nach dem Schema des Befehlszyklus unter Anwendung der Pipelining-Verarbeitung.

Phasen der Befehlsausführung als Stufen einer Pipeline, so kann man die Befehlsausführung auch anders, überlappend, organisieren. Man nutzt also aus, dass die auf einem Prozessor befindlichen Funktionseinheiten bei der Abarbeitung eines Befehls kaum alle gleichzeitig beansprucht werden. Wenn ein Befehl eine Phase abschließt, so muss diese Phase nicht bis zum Abschluss der gesamten Befehlsabarbeitung ungenutzt bleiben, sondern der nächste Befehl könnte direkt diese Phase betreten. Somit wird innerhalb der Pipeline versucht, alle Stufen gleichzeitig für aufeinanderfolgende Befehle zu nutzen und somit die Hardware-Auslastung zu verbessern. Dadurch werden mehrere Befehle gleichzeitig abgearbeitet. Die Pipeline-Verarbeitung kommt in vielen modernen Prozessoren zum Einsatz.

Die Vorteile der Pipeline-Verarbeitung im Gegensatz zur Sequentialität des Befehlszyklus soll nun an Hand eines Beispiels der Abarbeitung von drei Befehlen verdeutlicht werden. Die Abbildung Grafische Darstellung der Abarbeitung von drei Befehlen nach dem Schema des Befehlszyklus unter Anwendung der Pipelining-Verarbeitung soll diesen Vorgang grafisch veranschaulichen. Nimmt man an, dass die Bearbeitung in jeder Phase im Optimalfall einen Taktzyklus benötigt, so dauert die Ausführung dieser drei Befehle ohne Pipelining ganze 15 Taktzyklen, während die Verwendung von Pipelining zu einer Abarbeitungsdauer von 8 Taktzyklen führt. Dies entspricht nahezu einer Halbierung der benötigten Zeit, ohne zusätzliche Hardware ankaufen zu müssen. Des Weiteren wird, sobald die Pipeline-Bearbeitung begonnen hat, - zumindest theoretisch, falls keine Verzögerungen eintreten - in jedem Taktzyklus ein Befehl abgeschlossen, während dies bei der sequentiellen Bearbeitung nur alle fünf Taktzyklen passiert. Somit wird klar, dass sich Pipelining durchaus lohnt. Nicht immer kann eine Pipeline allerdings optimal ausgenutzt werden. Wenn beispielsweise Datenabhängigkeiten bestehen, das bedeutet das berechnete Ergebnis eines Befehls ist Voraussetzung für die Ausführung eines folgenden Befehls, müssen sogenannte Wartetakte eingeführt werden, welche die Ausführung verzögern. [18]

Quelle (zitieren ist schwierig, muss noch eine Lösung gefunden werden):
<https://www.elektronik-kompodium.de/sites/com/1705221.htm> -> Vielleicht Netzwerktechnik-Fibel: Grundlagen, Übertragungstechnik und Protokolle, Anwendungen und Dienste, Sicherheit -> Buch zur Webseite

2.2.1.2 Vektorrechner

Eine weitere Möglichkeit der Realisierung von Parallelem Rechnen sind die sogenannten *Vektorrechner*, auch *Vektorprozessoren* oder *Arrayrechner* genannt.

Das im Namen dieser Technologie enthaltene *Vektor* oder *Array* rührt daher, dass die gleichen Berechnungen gleichzeitig auf einer Menge von Daten ausgeführt werden. Diese Daten sind in diesem Fall meist in Form eines n -elementigen Arrays, also eines n -dimensionalen Vektors, organisiert. Diese Art der Prozessoren sind den gewöhnlichen CPUs, welche die gleiche Operation nacheinander auf den Daten ausführen würden, um ein vielfaches überlegen, falls es sich bei der zu bewerkstellenden Aufgabe um eine Operation handelt, die auf viele Daten ausgeführt werden muss. Somit können sich erhebliche Performance-Gewinne erzielen lassen.

Vektorrechner werden vor allem in der Simulationstechnik verwendet, wo viele gleichartige Daten auf gleiche Weise verarbeitet werden müssen. Dies ist beispielsweise in der Geologie und Meteorologie des Öfteren der Fall. Allerdings birgt diese Technologie den Nachteil, dass keine Standard-CPU's hier verwendet werden können, da das Vektorrechnen in der Hardware der CPU implementiert sein muss. Aus diesem Grund ergeben sich für Vektorrechner meist erhöhte Kosten im Vergleich zu gewöhnlichen Prozessoren. In der jüngeren Vergangenheit entfernte sich der Trend somit von dieser Art der Parallelrechner und ging zu großen Rechen-Clustern über. Dies sind Verbünde von vielen Standardprozessoren, die über schnelle Leitungen verbunden sind. Dadurch können Kosten eingespart werden, da durch die industrielle Herstellung der Preis von gewöhnlichen CPUs stark gesunken ist.

Da gewöhnliche CPUs nicht in Vektoren von Daten arbeiten können, werden sie mit Betrachtung der mathematischen Hintergründe auch *Skalarprozessoren* genannt. [19]

2.2.2 Implementierungsmöglichkeiten der Parallelisierung auf Softwareebene

Softwaretechnisch existieren im Allgemeinen genau zwei grundlegende Arten, um Parallelisierung zu implementieren: *Prozesse* und *Threads*. Dabei spielt das Betriebssystem eines Rechners eine zentrale Rolle, da es dem Software-Entwickler die nötigen Instrumente zur Verfügung stellt, um solche Prozesse und Threads zu erstellen. Heutige Rechner sind dazu

in der Lage, mehrere Aktionen gleichzeitig zu erledigen. Ein Computer liest beispielsweise Daten von der Festplatte, gibt Inhalte auf dem Bildschirm aus und gleichzeitig laufen auch noch einige Anwendungsprogramme des jeweiligen Benutzers.

Zunächst muss klargestellt werden, dass ein gewöhnlicher Rechner nicht so viele CPUs enthält wie Aufgaben abzuarbeiten sind und der Prozessor somit dazu gezwungen ist, zwischen der Abarbeitung der einzelnen Programme zu wechseln. Zu jedem beliebigen Zeitpunkt wird also stets nur ein Programm gleichzeitig auf einer CPU bearbeitet. Durch das schnelle Wechseln zwischen den Programmen wird beim Benutzer die Illusion von Parallelität geweckt. Um eine klare Abgrenzung zwischen dieser vorgetäuschten Parallelität und der echten Hardware-Parallelität zu schaffen, spricht man von *Quasiparallelität*. [1]

2.2.2.1 Das Prozess-Modell [1]

Im Rahmen des Modells ist die Gesamtheit aller ausführbaren Programme als eine Menge von sequentiellen Prozessen organisiert. Solche sequentielle Prozesse werden oft auch nur Prozesse genannt. Ein Prozess ist dabei ein Programm in Ausführung, wobei zentrale Aufgaben wie beispielsweise die Zuteilung der Ressourcen (z.B. CPU) dem Betriebssystem überlassen werden.

Für jeden Prozess wird der Eindruck erweckt, dass er selbst eine CPU zur Verfügung hat und jeder Prozess somit tatsächlich parallel abläuft. In der Realität ist dies nur selten der Fall, meist handelt es sich bei dieser CPU nur um eine virtuelle CPU und die reale CPU schaltet zwischen den Prozessen hin- und her. Folglich kommt meist Quasiparallelität zum Einsatz. Die kleinen Einheiten an Rechenzeit, welche die einzelnen Prozesse erhalten, werden als Zeitscheiben bezeichnet.

Jeder Prozess besitzt eine individuelle Aufgabe und auch eine eigene Ablaufsteuerung, also auch einen eigenen Befehlszähler, welcher angibt, welcher Befehl des Programmes als Nächster abgearbeitet werden muss. Somit ist die grundlegende Idee, dass jeder Prozess eine Aktivität beliebiger Art ist. Er hat ein Programm, welches festlegt, wie die Aufgabe abgearbeitet werden muss, Eingabedaten, Aufgabedaten und einen Zustand. Das Programm beschreibt im Unterschied zum Prozess also nur das Verfahren, also den Algorithmus, mit welchem eine Aufgabe gelöst werden soll. Die Aktivität des Lösen dieser Aufgabe unter der Verwendung des Programmes kann dann als Prozess bezeichnet werden. Der Ansatz des Erstellens von mehreren Prozessen auf einem Rechner wird auch als **Multiprocessing** bezeichnet.

Prozesszustand Obwohl jeder Prozess eine unabhängige Einheit darstellt, kommt es oft zu Situationen, in welchen Prozesse sich aus-

tauschen müssen, um Aufgaben korrekt zu erledigen.

Führt ein Prozess A beispielsweise eine Berechnung durch, die zu einem Ergebnis führt, welches von einem weiteren Prozess B benötigt wird, damit selbiger eine Aufgabe abarbeiten kann, so muss der Prozess B so lange blockiert werden, bis die Ergebnisse von Prozess A zur Verarbeitung bereitstehen.

Des Weiteren ist es möglich, dass die Zeitscheibe eines Prozesses, der gerade eine Aufgabe mit Hilfe der CPU erledigt, abläuft. Somit wäre er zwar rechenbereit, kann allerdings keine Berechnungen durchführen, da er im Moment nicht über eine Ausführungseinheit verfügt.

Ein Prozess kann folglich fünf grundlegende Zustände annehmen.

1. **Erstellt-Zustand:** Der Prozess wurde erstellt und ist bereit, die ihm zugewiesene Aufgabe abzuarbeiten.
2. **Rechnender Zustand, Aktiv-Zustand:** Der Prozess führt gerade Berechnungen unter Verwendung der CPU durch.
3. **Rechenbereiter Zustand, Bereit-Zustand:** Der Prozess wäre zum Rechnen in der Lage, verfügt im Moment aber über keine CPU.
4. **Blockiert-Zustand:** Der Prozess ist nicht zum Rechnen imstande, bis ein bestimmtes Ereignis eintritt, also bis beispielsweise Daten zur Verfügung stehen. In diesem Beispiel kann der Prozess auch, falls er gerade die CPU erhalten würde, keine Berechnungen durchführen. Das Zuteilen von Ressourcen an einen blockierten Prozess ist folglich nicht sinnvoll.
5. **Beendet-Zustand:** Der Prozess hat seine Aufgabe vollfüllt oder wurde auf Grund eines Problems beendet.

Die folgende Grafik soll die Prozesszustände nochmals verdeutlichen. Dabei ist der Übergang vom aktiven in den blockierten Zustand der einzige Zustandswechsel, den der Prozess selbst auslösen kann. Alle anderen werden vom Betriebssystem veranlasst.

Prozesshierarchie Ein Prozess ist dazu in der Lage, weitere Prozesse zu starten. Startet ein Prozess A einen neuen Prozess B, so bildet sich zwischen den beiden Prozessen eine Hierarchie: Der Prozess A ist der Vaterprozess, während der Prozess B der Kindprozess ist. Jeder Prozess hat dabei genau einen Vaterprozess, allerdings beliebig viele Kindprozesse.

Aus dem obigen Konzept wird nicht klar, wie ein Rechner-System startet, da zu Beginn ein Prozess gestartet werden muss, welcher der erste Prozess ist und somit keine Vaterprozess haben kann.

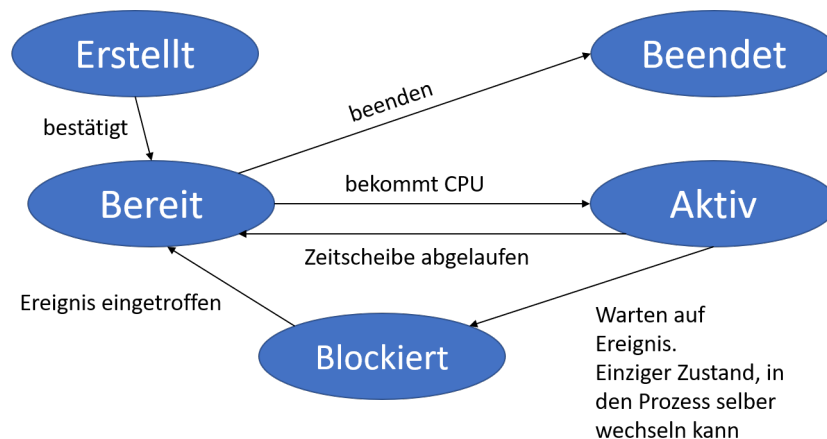


Abbildung 2.2: Grafische Darstellung der grundlegenden Prozesszustände.

Das Betriebssystem UNIX löst diese Problematik mittels eines eigenen Prozesses mit dem Namen *init*, welcher sich im Boot-Abbild des System gespeichert ist. Beim Systemstart wird dieses Boot-Image gelesen und der Prozess *init* erzeugt. Dieser Prozess kann dann wiederum Kindprozesse starten, welche dann wiederum Kindprozesse starten können usw. Somit initialisiert sich das Betriebssystem beim Start selbst. Somit ergibt sich eine das gesamte System umfassende Prozess-Hierarchie, wobei diese baumartig aufgebaut ist und die Wurzel des Baumes der Prozess *init* ist. Unter Windows gibt es kein Konzept der Prozesshierarchie, alle Prozesse sind hier gleichwertig.

Eigenschaften eines Prozesses Ein Prozess hat einige wichtige Eigenschaften. Auf die wichtigsten soll im Folgenden eingegangen werden.

- Jeder Prozess besitzt eine eigene Prozessumgebung. Das bedeutet, er besitzt eine eigene Aufgabe, einen eigenen Speicher-Adressraum und auch einen eigenen Ausführungsfaden. Das bedeutet, dass jeder Prozess seine Aufgabe individuell abarbeiten kann.
- Jeder Prozess kann andere Prozesse erzeugen, welche dann Kindprozesse genannt werden.
- Jeder Prozess kann mit anderen Prozessen kommunizieren. Man spricht hier von IPC (Inter-Prozess-Kommunikation), wobei das Betriebssystem Kommunikations-Methoden anbietet.

- Jedem Prozess wird ein sogenannter *Adressraum* zugeordnet. Dieser besteht aus einer Liste von Speicherstellen, auf die der Prozess Lese- und Schreibzugriffe ausführen darf.
- Prozesse können voneinander abhängen. Dies ist beispielsweise der Fall, wenn ein Prozess erst arbeiten kann, sobald er das Ergebnis eines anderen Prozesses erhalten hat. In diesem Fall ist Prozess-Synchronisation nötig, auf welche in Punkt PUNKT EINFÜGEN eingegangen wird.

Scheduling von Prozessen Auf den modernen Betriebssystemen ist die Existenz mehrerer Prozesse zur gleichen Zeit keine Seltenheit, sondern die Regel. Falls weniger physikalische CPUs vorhanden sind wie parallel ablaufende Prozesse, so müssen die CPUs zwischen verschiedenen Prozessen wechseln. Des Weiteren muss es eine Instanz geben, welche entscheidet, welcher Prozess als Nächster eine Zeitscheibe zugewiesen bekommt und auch die Länge der Zeitscheibe muss festgelegt werden. Der Teil des Betriebssystems, welche für diese Aufgaben zuständig ist, wird *Scheduler* (englisch für *Zeitplaner*) genannt.

Der Scheduler teilt den Prozessen folglich die CPU zu. Der Scheduler weiß allerdings nie genau, welche Ressourcen in Zukunft angefragt werden und welche zur Verfügung stehen werden. Der Scheduling-Algorithmus muss daher schätzen und muss dynamisch auf Änderungen reagieren. Es gestaltet sich folglich schwierig, ein geeignetes Verfahren zu finden, um den nächsten Prozess, der eine Zeitscheibe erhalten soll, auszuwählen. Aus diesem Grund haben sich verschiedene Strategien im Lauf der Geschichte entwickelt. Im Folgenden werden exemplarische einige Strategien erklärt.

1. **Scheduling in Stapelverarbeitungs-Systemen: First Come - First Serve (FCFS)**: Den Prozessen wird die CPU in der Reihenfolge zugewiesen, in der sie sie anfordern. Somit entsteht eine Warteschlange von rechenbereiten Prozessen. Sobald ein Prozess in der blockierten Zustand übergeht, kommt der nächste Prozess an die Reihe und der blockierte Prozess reiht sich nach dem Verlassen des blockierten Zustandes wieder in die Warteschlange ein. Ein Vorteil dieses Verfahrens ist, dass die CPU optimal ausgenutzt wird. Allerdings kann die Abarbeitung eines aufwendigen Prozesses die Abarbeitung kleiner Prozesses verzögern oder sogar verhindern.
2. **Scheduling in Stapelverarbeitungs-Systemen: Shortest Job First (SJF)**: Bei diesem Algorithmus wird davon ausgegangen, dass die Abarbeitungszeiten, also die Zeiten, wie lan-

ge die Prozesse zur Abarbeitung benötigen, im Vornherein bekannt sind. Dies ist beispielsweise anhand von Erfahrungswerten möglich. Der Prozess, der die kleinste Abarbeitungszeit besitzt, bekommt in diesem Fall die CPU. Dieses Verfahren funktioniert, falls die Abarbeitungszeiten durch Erfahrungen bekannt sind. Allerdings kann es passieren, dass sich die Bearbeitung aufwendiger Prozesses verzögert oder im schlimmsten Fall diese Prozesse die CPU sogar nie bekommen.

3. **Scheduling in interaktiven Systemen: Round-Robin-Scheduling (Zeitscheiben-Verfahren):** Dies ist einer der am meisten verwendeten Scheduling-Strategien. Jedem Prozess wird dabei eine Zeitscheibe zugewiesen, für welchen er die CPU bekommt. Nach Ablauf der Zeitscheibe wird dem Prozess der Prozessor entrissen und an den nächsten Prozess gegeben. Falls der Prozess vor Ablauf der Zeitscheibe blockiert oder beendet wird, so endet seine Zeitscheibe vorzeitig und der nächste Prozess kann mit seinen Berechnungen beginnen. Somit ergibt sich auch hier eine Warteschlange, wobei jeder Prozess der Reihe nach die CPU bekommt und sich nach der Bearbeitung durch die CPU entweder beendet, blockiert wird oder sich wieder am Ende der Warteschlange einreiht. Im einfachsten Fall des Round-Robin-Verfahrens wird davon ausgegangen, dass alle Prozesse gleich wichtig sind und somit alle Prozesse gleich große Zeitscheiben zugewiesen bekommen. Eine Abwandlung dieses Verfahrens ist das Weighted-Round-Robin-Scheduling. Bei diesem Algorithmus können die Zeitscheiben je nach Prozess unterschiedlich lang sein. Ein Nachteil dieses Verfahrens ist allerdings, dass dringende Prozesse nicht vorgezogen werden können.
4. **Scheduling in interaktiven Systemen: Prioritätenbasiertes Scheduling:** Bei Verwendung des Round-Robin-Scheduling ist jeder Prozess gleich wichtig. Denkt man allerdings an die Realität, so gibt es des Öfteren Aktivitäten, die wichtiger sind als andere. Ein Prozess, der im Hintergrund E-Mails verschickt, sollte von geringerer Wichtigkeit sein als ein Prozess, der für die Darstellung von Videos in Echtzeit zuständig ist. Aus diesem Grund stellt das prioritätenbasierte Scheduling eine Weiterentwicklung des Round-Robin-Scheduling dar. Jeder Prozess bekommt bei diesem Verfahren zusätzlich eine Priorität zugewiesen und der Prozess mit der aktuell höchsten Priorität erhält die CPU. Jedem Prozess muss in diesem Zusammenhang auch noch eine maximale Zeitscheiben-Dauer zugewiesen werden, um zu verhindern, dass der Prozess mit

der größten Priorität ewig läuft. Nach dem Ablauf dieses Maximums an CPU-Zeit muss dann ein Prozesswechsel passieren, wobei der Prozess mit der nächstgrößten Priorität an die Reihe kommt. Bei mehreren Prozessen mit gleich großer Priorität kann FCFS angewendet werden.

2.2.2.2 Das Thread-Modell [1]

Im Rahmen des bereits bekannten Prozess-Modells hat jeder sequentielle Prozess einen eigenen Adressraum und auch einen eigenen Ausführungsfaden, wobei die einzelnen Prozesse auf einem System parallel zueinander ablaufen.

Es hat sich allerdings herausgestellt, dass es oft von Vorteil ist, mehrere Ausführungsfäden parallel bzw. quasiparallel zueinander innerhalb desselben Adressraums ablaufen zu lassen. Die einzelnen Ausführungsfäden verhalten sich dann ähnlich wie getrennte Prozesse, wobei der größte Unterschied der gemeinsame Adressraum darstellt.

Die zwei Grundkonzepte von Prozessen sind die Bündelung der Ressourcen und die Ausführung.

- Ein Prozess lässt sich als eine Gruppierung von Ressourcen unterschiedlichster Art betrachten. Dazu zählen Quelltext, Programm-Daten, geöffnete Dateien, und vieles mehr. All diese Ressourcen sind im Adressraum des Prozesses und somit im Hauptspeicher des Rechners abgelegt.
- Das zweite wichtige Konzept ist die Ausführung. Ein Prozess besitzt im Normalfall genau einen *Ausführungsfaden* oder auf englisch auch *Thread*¹ genannt. Eigentlich besitzt nicht der Prozess selbst, sondern der ihm innewohnende Thread den Befehlszähler, welcher angibt, welcher Befehl als nächstes abgearbeitet werden soll.

Ein Thread ist zwar stets von seinem Prozess existenzabhängig, jedoch sind Prozess und Thread zwei getrennte Konzepte. Das Konzept von Threads erweitert das Prozess-Modell, da ein Prozess nicht nur einen Thread enthalten kann, sondern beliebig viele. Somit können mehrere Ausführungsfäden, welche voneinander unabhängig sind, innerhalb einer Prozessumgebung mit einem gemeinsamen Adressraum, realisiert werden. Durch die Einführung von Threads wird ein Prozess auf das Prinzip

¹Der englische Begriff *Thread* kann mit dem deutschen Wort *Faden* übersetzt werden.

der Zusammenfassung von Ressourcen und des Bereitstellen einer Umgebung für seine Threads reduziert.

Mehrere Threads parallel innerhalb eines Prozesses laufen zu lassen verhält sich ähnlich wie mehrere Prozesse parallel auf einem Rechner laufen zu lassen. Im ersten Fall teilen sich die Threads die Ressourcen des Prozesses (Adressraum, geöffnete Dateien, ...), im zweiten Fall teilen sich die Prozesse die Ressourcen des Rechners (Festplatte, Drucker, ...). Threads und Prozesse befinden sich allerdings auf verschiedenen Ebenen.

Threads werden in der Fachliteratur auf Grund ihrer Ähnlichkeit zu Prozessen manchmal auch als *leichtgewichtige Prozesse* bezeichnet.

Der Ansatz des Erstellens von mehreren Threads innerhalb eines Prozesses wird auch als **Multithreading** bezeichnet. Läuft auf einem System mit nur einer CPU ein Prozess mit mehreren Threads, so wechseln sich die Threads in der Ausführung ab. Die CPU wechselt ähnlich zu den Prozessen auch hier zwischen den Threads, sodass wiederum die Illusion von parallel ablaufenden Threads erzeugt wird.

Eigenschaften von Threads Ein Thread hat einige wichtige Eigenschaften, die ihn von einem Prozess unterscheiden. Auf die wichtigsten soll im Folgenden eingegangen werden.

- Alle Threads eines Prozesses teilen sich die Ressourcen des Prozesses und somit auch seinen Adressraum. Damit geht einher, dass alle Threads dieselben globalen Variablen besitzen. Die Threads teilen sich somit auch beispielsweise alle geöffneten Dateien und ähnliche Ressourcen des Prozesses. Dabei kann es zu unvorhergesehenen Problemen, sogenannten *zeitkritischen Abläufen*, kommen. Diese potentiell gefährlichen Situationen lassen sich mittels *Prozess-Synchronisation* lösen, auf welche in Punkt HIER EINFÜGEN eingegangen wird.
- Ein Thread kann wie auch jeder Prozess in Zustände wie unter Punkt Das Prozess-Modell [1] beschrieben geraten. Die fünf Grundzustände lauten auch hier Erstellt-Zustand, Aktiv-Zustand, Bereit-Zustand, Blockiert-Zustand und Beendet-Zustand.
- Threads dienen der Erstellung mehrerer Ausführungsfäden, welche sich die Ressourcen des Prozesses, zu dem sie gehören, teilen und somit eng und schnell an einer gemeinsamen Aufgabe arbeiten können.
- Auch zwischen Threads können Hierarchien analog zu Prozessen aufgebaut werden. Dabei sei auf den Punkt Das Prozess-Modell [1] verwiesen.

Fork-Join-Modell bei Threads Während Prozesse meist vollkommen unterschiedliche Aufgaben erledigen, arbeiten bei Einsatz von Mul-

tithreading die Threads eines Prozesses meist gemeinsam an einem Problem. Hier bietet sich das unter Punkt erwähnte Fork-Join-Modell an.

Dabei startet ein Prozess zunächst mit einem einzigen Thread, dem Haupt-Abarbeitungsstrang. Dieser Thread verfügt über die Möglichkeit, neue Threads zu erzeugen. Der Haupt-Thread muss dabei den Kind-Threads mitteilen, welche Aufgabe sie lösen müssen. Der Haupt-Thread kann nun entweder selbst auch Berechnungen durchführen oder auch direkt auf die Beendigung seiner Kind-Threads warten und das Ergebnis der einzelnen Threads aufsammeln und zu einer Gesamt-Lösung kombinieren.

Verwendung von Threads Threads werden immer dann verwendet, wenn innerhalb einer Anwendung mehrere Aufgaben gleichzeitig bewältigt werden müssen, wobei sich diese Aktivitäten gegenseitig blockieren können. Das Aufspalten einer Anwendung in mehrere quasi-parallel ablaufende Threads vereinfacht auch die Programmierung.

Das zuvor genannte Konzept des gemeinsamen Adressraums ist das zentrale Konzept für die Verwendung von Threads. Threads erweitern somit das Prozess-Modell um die Fähigkeit von quasi-parallel ablaufenden Strängen, die die Daten und Ressourcen des Prozesses gemeinsam nutzen.

Ein weiteres Argument für die Verwendung von Threads ist, dass sie an keine Ressourcen wie z.B. offene Dateien gebunden sind, und somit schneller erstellt und zerstört werden können. In vielen Systemen ist die Erstellung eines Threads 100 Mal schneller durchgeführt als die Erstellung eines Prozesses.

Joinable und Detached Threads Normalerweise sind Threads *joinable*. Dies bedeutet, dass man vom Vater-Thread aus durch Aufruf einer bestimmten vom Betriebssystem zur Verfügung gestellten Funktion auf die Beendigung des jeweiligen Kind-Threads warten kann. Der diese Funktion aufrufende Vater-Thread wird dabei so lange blockiert, bis der Kind-Thread beendet wurde. Dann kann der Vater-Thread auch eventuelle Rückgabewerte des Kind-Threads einsammeln. Ein joinable Thread *joint* (zu Deutsch *zusammenstürmen*) also zum Vater-Thread zurück, bevor er sich beendet. Ein joinable Thread wird so lange nicht als beendet betrachtet, bis er mit einem anderen Thread gejoint wird.

Oft kommt es allerdings auch vor, dass ein Kind-Thread nichts zurückgibt und somit kein Bedarf besteht, dass der Vater-Thread auf die Beendigung des Kind-Threads warten muss. Setzt man bei einem Thread die Eigenschaft von *joinable* auf *detached* (zu

Deutsch *losgelöst*), so wird dem System klargemacht, dass man einen Thread erstellt, auf dessen Beendigung nicht gewartet werden muss. Somit wird dieser losgelöste Thread beendet, sobald er seine Aufgabe erledigt, wobei kein Join-Vorgang nötig ist, oder sobald der Prozess, zu welchem er gehört, beendet wird. [9] [20]

Scheduling von Threads Auf modernen Systemen ist es die Regel, dass mehrere Prozesse parallel ablaufen, welche wiederum jeweils aus mehreren Threads bestehen. Somit liegen zwei verschiedene Ebenen der Parallelität vor, nämlich Prozesse und Threads gleichzeitig. Für das Scheduling in diesem Fall gibt es grundsätzlich zwei verschiedene Ansätze.

Der erste Ansatz ist dem Prozess-Scheduling sehr ähnlich. Der Prozess-Scheduler weist dabei einfach den einzelnen Prozessen nacheinander die CPU zu, ohne Rücksicht auf die Threads innerhalb der Prozesse zu nehmen. Somit muss in jedem Prozess nochmals ein Thread-Scheduler existieren, welcher dann den Thread auswählt, der die CPU tatsächlich bekommt. Innerhalb einer Zeitscheibe eines Prozesses können somit mehrere Threads bearbeitet werden, da der Thread-Scheduler die Prozess-Zeitscheibe nochmals in kleinere Zeitscheiben unterteilt, welche dann wiederum den Threads zugewiesen werden. Bei diesem Ansatz können sowohl der Prozess-, als auch der Thread-Scheduler Strategien anwenden, welche ähnlich zu den unter Punkt Das Prozess-Modell [1] genannten Strategien sind. Der zweite Ansatz besteht darin, dass der Scheduler nicht mehr zwischen Prozessen unterscheidet, sondern nur noch über eine Liste von Threads verfügt, von denen er weiß, dass diese rechenbereit sind. Somit wird die Grenze zwischen den Prozessen aufgehoben und der Fokus liegt auf den Threads. Auch bei diesem Ansatz kann der Scheduler Strategien anwenden, welche ähnlich zu den unter Punkt Das Prozess-Modell [1] genannten Strategien sind.

2.3 Prozess-Synchronisation [1]

Auch wenn Prozesse an sich als vollkommen voneinander unabhängige Abarbeitungseinheiten betrachtet werden können, besteht doch in vielen Fällen die Notwendigkeit, dass Prozesse untereinander kommunizieren müssen. Diese Art des Austausches von Informationen wird als *Interprozesskommunikation*, kurz *IPC*, bezeichnet.

Dabei müssen allerdings drei wichtige Punkte beachtet werden.

- Den Prozessen müssen Möglichkeiten des Austausches von Informationen bereitgestellt werden.

- Mehrere kooperierende Prozesse dürfen sich bei kritischen Aktivitäten in die Quere kommen.
- Falls Abhängigkeiten zwischen Prozessen vorliegen, so müssen diese sauber abgearbeitet werden.

Ein häufiges bei der IPC auftretendes Problem sind die bereits schon erwähnten *kritischen Aktivitäten* oder auch *Zeitkritischen Abläufe*, auf welche im Folgenden eingegangen werden soll.

2.3.1 Probleme bei der parallelen Bearbeitung

2.3.1.1 Zeitkritischer Ablauf

Bei diesem Problem wird davon ausgegangen, dass mehrere Prozesse arbeiten und über eine gemeinsame Ressource verfügen, auf die alle zugreifen können. Eine solche Ressource ist in vielen Fällen ein gemeinsamer Speicher. Dieser könnte sowohl im Hauptspeicher liegen, aber auch beispielsweise eine gemeinsame Datei sein. Der Einfachheit wegen wird nun von zwei Prozessen A und B ausgegangen, die über eine gemeinsame Speicherressource kommunizieren.

Um die Natur der ICP und die dabei auftretenden Probleme zu begreifen, soll nun auf ein häufig in diesem Zusammenhang erwähntes und alltagstaugliches Beispiel eingegangen werden.

Beispiel Drucker-Spooler Um dieses Beispiel zu verstehen, muss zunächst klargestellt werden, dass jedem Prozess grundsätzlich zu jeder Zeit die CPU entrissen werden kann. Der Prozess speichert in diesem Fall seinen aktuellen Zustand und sobald er wieder eine Zeitscheibe zugeteilt bekommt, fährt er genau da fort, wo er zuvor aufgehört hat. In diesem Beispiel wird angenommen, dass zwei Prozesse Dokumente drucken wollen. Um dies zu erreichen, tragen sie den Dateinamen des zu druckenden Dokumentes in eine Spooler-Warteschlange² ein. Ein dritter Prozess überprüft in bestimmten zeitlichen Abständen, ob neue Druckaufträge aufgegeben wurden, initiiert den Druckauftrag und löscht den Auftrag aus der Spooling-Warteschlange.

Des Weiteren wird angenommen, dass die Warteschlange aus nummerierten Einträgen (0, 1, 2, ...) besteht, wobei jeder Eintrag genau ein zu druckendes Dokument aufnehmen kann. Beide Prozesse sind dazu in der Lage, den Index des nächsten freien Eintrages in der

²Spooling (*Simultaneous Peripheral Operation On-Line*) ist ein Begriff, welcher oft in Zusammenhang mit Betriebssystemen genannt wird. Damit meint man einen Vorgang, bei welchen zu bearbeitende Aufträge in einen Speicher geschrieben werden, bevor sie der eigentlichen Verarbeitung zugeteilt werden. [21]

Spooler-Warteschlange auszulesen.

Der kritische Punkt wird in dem Moment erreicht, sobald sich beide Prozesse (annähernd) gleichzeitig dafür entscheiden, ein Dokument zum Drucken in die Warteschlange einreihen zu wollen.

Prozess A bekommt also vom Scheduler eine Zeitscheibe zugewiesen und darf rechnen. Er speichert den aktuell nächsten freien Eintrag in der Warteliste, beispielsweise 7, in seiner lokalen Variable *nextFreeSlot*. Nach dieser Aktion läuft seine Zeitscheibe ab und der Prozess B darf nun Berechnungen durchführen. Da auch er einen Druck in Auftrag geben möchte, speichert auch er den aktuell nächsten freien Eintrag in der Warteliste, welcher immer noch 7 ist, in seiner lokalen Variable *nextFreeSlot*. Beide Prozesse sind also der Ansicht, dass der nächste freie Eintrag in der Spooler-Warteschlange 7 ist. Die Zeitscheibe von Prozess B ist noch nicht abgelaufen, weshalb er nun den Dateinamen der von ihm zu druckenden Datei in den noch freien Eintrag 7 der Warteschlange einreicht, weshalb nun der Index des nächsten freien Eintrag in der Warteliste 8 beträgt. Prozess B hat seine Arbeit erledigt und gibt die CPU frei bzw. seine Zeitscheibe läuft ab. Nun wird der Prozessor folglich wieder dem Prozess A zugeteilt, welcher genau an der Stelle weiterarbeitet, an der er zuvor unterbrochen wurde. Er liest den Wert von seiner lokalen Variable *nextFreeSlot* aus und stellt fest, dass laut dieser Variable der Index des nächsten freien Eintrag in der Warteliste 7 ist. Aus diesem Grund schreibt er den Dateinamen der von ihm zu druckenden Datei in den seiner Ansicht nach freien Eintrag 7 der Warteschlange. Tatsächlich ist der Eintrag aber zuvor nicht leer gewesen, weshalb der Prozess A den Druckauftrag von Prozess B unwiderruflich gelöscht hat.

Der Drucker-Spooler kann über diese Inkonsistenz³ nicht Bescheid wissen und wird den Auftrag von Prozess A drucken, während der Druckauftrag von Prozess B nie vollführt werden wird. Die Abbildung Abbildung 2.3 soll die genannte Problematik nochmals grafisch verdeutlichen.

Solche Situationen, in denen mehrere Prozesse schreibend und lesend auf gemeinsame Ressourcen zugreifen und der Erfolg oder Misserfolg des gesamten Ablaufes davon abhängt, welcher Prozess wann genau arbeiten kann, nennt man **zeitkritische Abläufe**.

Solche Fehler lassen sich auch im Quellcode eines Programmes nur äußerst schwierig finden, da die Programme meistens problemlos funktionieren und nur manchmal das Problem auftritt.

Kritischer Abschnitt Nun wird die in Punkt Zeitkritischer Ablauf genannte Problematik nicht mehr abstrakt, sondern auf Ebene des

³Unstimmigkeit, Widersprüchlichkeit




Abbildung 2.3: Grafische Darstellung des Drucker-Spoolers als ein Beispiel für einen zeitkritischen Ablauf.

Quellcodes der beteiligten Prozesse betrachtet.

Solange die Prozesse auf keine gemeinsamen Ressourcen zugreifen, kann es zu keinen zeitkritischen Abläufen kommen. Nur das lesende und schreibende Zugreifen auf Ressourcen, auf welche mehrere Prozesse Zugriff besitzen, kann zu dieser Art von Problemen führen. Die Teile eines Programmes, in welchen ein Zugriff auf solche gemeinsam genutzt Ressourcen erfolgt, nennt man **kritische Region** oder auch **kritischer Abschnitt**.

Um dieses Problem zu lösen, muss man auf ein Konzept von höchster Wichtigkeit in Zusammenhang mit dem parallelen Programmierparadigma, nämlich auf die *Prozess-Synchronisation*, zurückgreifen. Mögliche Lösungsansätze werden unter Punkt PUNKT HIER EINFÜGEN näher erläutert.

2.3.1.2 Verklemmung (Deadlock) [1]

Bei Rechnersystemen gibt es meist Ressourcen, die gleichzeitig nur einem Prozess zugewiesen werden können. Wenn zwei Prozesse gleichzeitig zwei Dokumente mit dem selben Drucker drucken möchten, so ist nicht klar, wie der Drucker vorgehen sollte und wird höchstwahrscheinlich nur unbrauchbare Dokumente drucken. Aus diesem Grund sind Betriebssysteme dazu in der Lage, Ressourcen für eine bestimmte Zeit nur einem einzigen Prozess zuzuweisen.

Nun existieren aber Situationen, in welchen ein Prozess mehrere (also n) Ressourcen gleichzeitig benötigt, um weiterarbeiten zu können. Das bedeutet, dass er erst aus dem Blockiert- in den Bereit- bzw. Aktiv-Zustand gelangen kann, sobald alleinig dem Prozess alle n Ressourcen zu Verfügung stehen. Ein Beispiel hierfür ist ein Prozess A, der ein Do-




Abbildung 2.4: Grafische Darstellung eines Deadlocks bei zwei Prozessen A und B und zwei Ressourcen 1 und 2.

kument einscannen und gleichzeitig auf dem Bildschirm den aktuellen Scann-Status anzeigen möchte. Um arbeiten zu können, benötigt dieser Prozess folglich die beiden Ressourcen Scanner und Bildschirm, um arbeiten zu können.

Im folgenden Szenario kommt es nun zu einem Problem. Auf einem System laufen zwei Prozesse A und B, wobei der Prozess B gerade den Scanner für sich reserviert hat und damit arbeitet. Sobald nun Prozess A an die Reihe kommt, fordert er die beiden Ressourcen Bildschirm und Scanner an. Da der Prozess B den Scanner gerade verwendet und für sich reserviert hat, kann der Prozess A nicht arbeiten, da er wie bereits erwähnt sowohl den Bildschirm als auch den Scanner benötigt, um arbeiten zu können, jedoch nur den Bildschirm erhält. Der Prozess A gelangt nun folglich in den Blockiert-Zustand und wartet, bis die Ressource Scanner freigegeben wird. Fordert nun der Prozess B auch noch den Bildschirm an und gibt den Scanner nicht frei, da er beispielsweise noch mit einem Scan-Vorgang beschäftigt ist, so geht auch der Prozess B in den Blockiert-Zustand, da er nicht alle von ihm angeforderten Ressourcen erhält. Ab diesem Zeitpunkt befinden sich beide Prozesse in einem Szenario, in welchem sie sich gegenseitig blockieren, sodass nie wieder einer der beiden den Blockiert-Zustand verlassen wird. Eine solche Situation nennt man *Deadlock* oder auch *Verklemmung*. [22]

Solche Deadlocks können auch zwischen mehr als zwei Prozessen und mehr als zwei Ressourcen entstehen. Die Situation einer Verklemmung bei zwei Prozessen A und B und zwei Ressourcen 1 und 2 ist in der Abbildung 2.4 schematisch dargestellt.

Formal lässt sich der Begriff Deadlock laut Andrew S. Tanenbaum wie folgt definieren:

Eine Menge von Prozessen befindet sich in einem Deadlock-

Zustand, wenn jeder Prozess aus der Menge auf ein Ereignis wartet, das nur ein anderer Prozess aus der Menge auslösen kann. [1]

Alle Prozesse dieser Menge befinden sich somit im blockierten Zustand und werden die Ereignisse, auf welche die anderen Prozesse dieser Menge warten, nie auslösen.

Behebung von Deadlocks Ist ein Deadlock aufgetreten, so muss das System wieder in einen verklemmungsfreien Zustand gelangen, um ordnungsgemäß arbeiten zu können. Im Folgenden der mehrere Möglichkeiten behandelt, um einen Deadlock in einem System zu beheben.

Behebung von Deadlocks durch Unterbrechung Eine Möglichkeit, einen Deadlock aufzuheben, besteht in der zeitweisen Suspendierung eines beteiligten Prozesses. Suspendieren bedeutet in diesem Fall, dass der Prozess als nicht ausführbar markiert wird. Somit können die Ressourcen, die ihm zugewiesen worden sind, nun anderen Prozessen zugeteilt werden. Dadurch kann ein Deadlock behoben werden. Sobald die anderen Prozesse ihre Arbeit erledigt haben und die Ressourcen freigeben, so kann der suspendierte Prozess wieder aktiviert werden und auch selbiger ist dann dazu in der Lage, seine Berechnungen durchzuführen. Die Auswahl des zu suspendierenden Prozesses muss dabei weise getätigt werden, da es sich bei den Ressourcen, die jener Prozess belegt, um solche handeln muss, die einfach entzogen und wieder zurückgegeben werden können.

Behebung von Deadlocks durch Rollback Ist beim Entwickeln eines Systems klar, dass beim Betrieb des Öfteren Deadlocks auftreten können, dann kann der Entwickler auch direkt eine Zusatzfunktion einbauen, die das Beseitigen von Deadlocks erleichtert. Dieser Zusatz erlaubt es dem System, den Zustand jedes Prozesses auf dem System in festgelegten Abständen (an *Checkpoints*) zu speichern, sodass der Prozess jederzeit in einen vergangenen Zustand zurückversetzt und von diesem aus neu gestartet werden kann. An jedem Checkpoint werden dann alle für den Zustand des Prozesses relevanten Informationen gesammelt. Dabei handelt es sich um den Speichereinhalt des Prozesses im Hauptspeicher, aber beispielsweise auch über die momentan vom Prozess belegten Ressourcen. Kommt es nun zu einem Deadlock, so können die benötigten Ressourcen ermittelt werden. Um die Verklemmung aufzulösen, wird nun ein Prozess, der eine Ressource besitzt, die von

einem anderen Prozess angefordert wird, einfach in einen Zustand zurückversetzt, in dem er die fragliche Ressource noch nicht reserviert hatte. Die somit freigegebene Ressource kann nun einem anderen Prozess, der auch am Deadlock beteiligt ist, zugeteilt werden. Die Arbeit, die der zurückgesetzte Prozess von dem Zeitpunkt der Erstellung des Checkpoints bis zum Zeitpunkt des Deadlocks geleistet hat, geht verloren. Sobald dieser Prozess die fragliche Ressource wieder anfordert, so muss er warten, bis sie wieder frei wird. Der Vorgang des Zurücksetzen eines Prozesses in einen vergangenen Zustand wird auch als *Rollback*⁴ bezeichnet.

Behebung von Deadlocks durch Prozessabbruch Die radikalste Methode zur Behebung einer Verklemmung ist der Abbruch eines oder mehrerer der am Deadlock beteiligten Prozesse. Die Schwierigkeit liegt dabei in der Bestimmung des abzubrechenden Prozesses. Der abzubrechende Prozess muss bei Abbruch genau die Ressourcen freigeben, sodass ein anderer am Deadlock beteiligter Prozess wieder weiterarbeiten kann. Des Weiteren sollte ein Prozess zum Abbruch ausgewählt werden, der einfach wieder gestartet werden kann. Ein Beispiel hierfür ein Compiler⁵. Der Ablauf eines Compilers kann immer wiederholt werden, da er nur eine Quellcode-Datei benötigt und daraus eine ausführbare Datei erstellt. Der erste, unterbrochene Durchlauf hat keinen Einfluss auf den neuen Ablauf. Anders ist dies beispielsweise bei Prozessen, die schreibend auf Datenbanken zugreifen. Addiert ein Prozess beispielsweise zu einer Zahl, die in einer Datenbank gespeichert ist, die Zahl 5, so kann ein abgebrochener und ein vollführter Durchlauf entweder dazu führen, dass die Zahl 5 addiert wird, oder auch, dass die Zahl 10 ($5 + 5$) addiert wird. Die Addition von 10 würde die Datenbank in einen inkonsistenten Zustand bringen.

Verhinderung von Deadlocks Noch besser als die Behebung eines Deadlocks ist es, sicherzustellen, dass ein Deadlock erst gar nicht eintreten kann.

Dabei liegt die Grundidee darin, dass ein Deadlock jedes mal eintreten kann, sobald das Betriebssystem einem Prozess eine (oder mehrere) Ressource(n) zuweist. Aus diesem Grund muss das System bei der Zuteilung von Ressourcen vorsichtig umgehen und

⁴zurückrollen, zurückdrehen

⁵Ein Compiler ist ein Programm, das Programm-Quellcode, welcher in einer bestimmten Programmiersprache verfasst wurde, in eine Form übersetzen kann, sodass ein Rechner zum direkten Ausführen des Programmes in der Lage ist. [23]

vor jeder Zuordnung überprüfen, ob diese zu einer Verklemmung führen kann oder nicht. Zunächst muss dafür das Konzept der *sicheren und unsicheren Zustände* eingeführt werden.

Sicherer und unsicherer Zustand Das System muss dazu in der Lage sein, seinen Zustand jederzeit selbst zu bewerten. Die Bewertung geschieht dabei in Hinblick auf die Verklemmungsfreiheit anhand der verfügbaren, freien, belegten und angeforderten Ressourcen. Dabei wird angenommen, dass ein Prozess eine bestimmte Anzahl von Ressourcen bereits belegt und weitere Ressourcen anfordert. Dabei weiß jeder Prozess, wie viele Ressourcen er maximal noch benötigt.

Einen Zustand des Systems nennt man sicher, wenn keine Verklemmung vorliegt und es eine Abarbeitungsreihenfolge der einzelnen Prozesse (also einen Scheduling-Algorithmus) gibt, die nicht zum Deadlock führt. Ein sicherer Zustand garantiert somit eine Reihenfolge der Abarbeitung und Ressourcenzuweisung, die zu einem erfolgreichen Terminieren aller beteiligten Prozesse führt. Überführt man das System immer nur von einem sicheren wieder in einen sicheren Zustand, so gibt es immer einen Weg zur Vermeidung eines Deadlocks. Gibt es der Reihe nach immer nur sichere Zustände, so erhält jeweils immer mindestens ein Prozess alle von ihm angeforderten Ressourcen und kann somit arbeiten, wodurch am Ende alle Prozesse arbeiten konnten und ein Deadlock verhindert wurde.

Umgekehrt ist bei einem unsicheren Zustand ein Zustand, in welchem keine deadlockfreie Abarbeitungsreihenfolge gegeben ist. Ein unsicherer Zustand führt allerdings nicht zwingend zu einer Verklemmung, tatsächlich könnten sogar alle Prozesse erfolgreich beendet werden, wenn ein Prozess nicht die maximal von ihm angegebene Anzahl an Ressourcen tatsächlich anfordert. Der Unterschied zwischen einem sicheren und einem unsicheren Zustand ist folglich, dass das System in einem sicheren Zustand garantieren kann, dass alle Prozesse bis zum Ende arbeiten können. In einem unsicheren Zustand kann das Betriebssystem dies nicht garantieren, was allerdings wie bereits angedeutet nicht zwingend zu einem Deadlock führen muss. [24]

Der Bankier-Algorithmus Ein Algorithmus zur Verhinderung von Deadlocks geht auf Edsger W. Dijkstra⁶ zurück.

Der Name kommt daher, dass das Betriebssystem mit Bedacht Ressourcen verteilen muss, um Deadlocks zu verhindern, und

⁶Edsger Wybe Dijkstra (1930 - 2002) war ein niederländischer Informatiker. [25]

dieser Sachverhalt eine gewisse Ähnlichkeit zu einem Bankier in einer Bank hat, welcher auch überlegen muss, welchen Kunden er Kreditwünsche gewährt und welchen nicht. Der Bankier (also der Algorithmus bzw. das Betriebssystem) überprüft bei jedem Kreditwunsch (also jeder Ressourcenanforderung), ob die Gewährung des Wunsches (also die Zuteilung der Ressource) zu einem unsicheren Zustand führt. Lediglich im Fall, dass der Kredit zu einem sicheren Zustand führt, wird er gewährt. [26]

Um diesen Algorithmus anwenden zu können, muss jedem Prozess bekannt sein, welche und wie viele Ressourcen er maximal benötigt. Jeder Prozess kann dann tatsächlich auch weniger Ressourcen anfordern, die als Maximum angegebene Anzahl darf aber keines Falles überschritten werden. Des Weiteren muss das System die Arten der verfügbaren Ressourcen und die Anzahl dieser Ressourcen ebenfalls kennen. Der Bankier-Algorithmus vergibt immer einem Prozess alle von ihm angeforderten Ressourcen, sodass selbiger seine Aufgabe erledigen kann. Sobald dieser Prozess seine Aufgabe erledigt hat, werden dem nächsten Prozess alle von ihm benötigten Ressourcen zugewiesen. So werden alle Prozesse der Reihe nach ordnungsgemäß abgearbeitet.

Der Algorithmus soll nun anhand eines Beispiels veranschaulicht werden. Dabei wird aber der Einfachheit wegen davon ausgegangen, dass es nur eine Art von Ressourcen gibt, sodass die Anzahl der von einem Prozess benötigten Ressourcen in einer einfachen Zahl ausgedrückt werden können.

Beispielsweise laufen auf einem System vier Prozesse A, B, C und D. Jedem Prozess sind zwei Zahlen zugewiesen: Die erste Zahl mit dem Namen *Anzahl belegte Ressourcen* entspricht der Anzahl von Ressourcen, die er belegt, die zweite Zahl mit dem Namen *Maximale Anzahl insgesamt benötigter Ressourcen* stellt die maximale Anzahl von Ressourcen dar, die er benötigt, um seine Aufgabe erledigen zu können. Das System verfügt über insgesamt 10 Einheiten derselben Ressource.

Nun wird angenommen, dass die Prozesse arbeiten, sodass es nach einer beliebigen Zeit zu einem der in den Tabellen Tabelle 2.1, Tabelle 2.2 und Tabelle 2.3 dargestellten Zustände kommt.

Zunächst wird angenommen, dass es zum ersten Zustand kommt.

Das Betriebssystem addiert in diesem Fall die Anzahl an Ressourcen, die alle Prozesse zusammen belegen, was in diesem Fall auf die Rechnung $0 + 0 + 0 + 0 = 0$ führt. Folglich sind im gesamten System zu diesem Zeitpunkt keine Ressour-

cen belegt. Das wiederum bedeutet, dass von den zehn dem System zur Verfügung stehenden Ressourcen alle 10 frei sind. Der Zustand, welcher in der Tabelle Tabelle 2.1 dargestellt ist, ist folglich sicher, da das Betriebssystem einem beliebigen Prozess die benötigten Ressourcen zuteilen kann, weil keiner der laufenden Prozesse mehr als 10 Ressourcen benötigt. Beispielsweise kann das System dem Prozess D die sieben benötigten Ressourcen zuteilen, sodass er seine Arbeit verrichten kann. Nachdem der Prozess D beendet ist, gibt er wieder alle sieben Ressourcen frei und das Betriebssystem kann dem nächsten Prozess alle benötigten Ressourcen zuweisen. So werden der Reihe nach alle Prozesse erfolgreich abgearbeitet. Es kann somit nicht zu einem Deadlock kommen.

Nun wird angenommen, dass das System in den zweiten Zustand gelangt. Das Betriebssystem addiert in diesem Fall wieder die Anzahl an Ressourcen, die alle Prozesse zusammen belegen, was auf die Rechnung $1 + 1 + 2 + 4 = 8$ führt. Folglich sind im gesamten System zu diesem Zeitpunkt acht Ressourcen belegt. Das wiederum bedeutet, dass von den zehn dem System zur Verfügung stehenden Ressourcen nur $10 - 8 = 2$ frei sind. Der Zustand, welcher in der Tabelle Tabelle 2.2 dargestellt ist, ist auch sicher, weil das Betriebssystem die zwei freien Ressourcen dem Prozess C zuweisen kann, welcher dann alle benötigten Ressourcen erhält und lauffähig ist. Nachdem dieser Prozess erfolgreich abgearbeitet wurde, gibt er alle von ihm belegten Ressourcen frei, wodurch im System dann vier Ressourcen frei sind. Das System kann dann dem entweder dem Prozess B alle vier Ressourcen zuweisen und ihn damit lauffähig machen, oder aber auch dem Prozess D drei Ressourcen zuteilen und ihn damit aus dem blockierten Zustand holen. Auf diese Weise können alle im System laufenden Prozesse zu einem erfolgreichen Ende gebracht werden. Ein Deadlock wurde vermieden.

Nimmt man nun eine kleine Veränderung am Zustand 2 vor, sodass der Prozess B anstatt einer bereits zwei Ressourcen besetzt, so kommt man zum dritten Zustand. Nun wird wieder die Anzahl an Ressourcen, die alle Prozesse zusammen belegen, durch Addition berechnet, was auf die Rechnung $1 + 2 + 2 + 4 = 9$ führt. Folglich sind im gesamten System zu diesem Zeitpunkt neun Ressourcen belegt. Das wiederum bedeutet, dass von den zehn dem System zur Verfügung stehenden Ressourcen nur $10 - 9 = 1$ frei ist. Der Zustand, welcher in der Tabelle Tabelle 2.3 dargestellt ist, ist somit unsicher. Wenn alle Prozesse gleichzeitig ihr Maximum an anzufordernden Res-

sources anfragen würden, so könnte das System keinem der Prozesse alle angeforderten Ressourcen zuweisen. Die direkte Folge wäre ein Deadlock, der mit einem der unter Punkt Verklemmung (Deadlock) [1] aufgelisteten Verfahren beseitigt werden müsste. Der unsicherer Zustand 3 führt allerdings nicht zwingend zu einem Deadlock, weil nicht jeder Prozess das Maximum an Ressourcen anfordern muss. Der Algorithmus kann allerdings diesen Faktor nicht vorhersagen und den Deadlockfreiheit ist nicht mehr garantiert. Der Algorithmus würde also eine Ressourcen-Anforderung, die zum Zustand 3 führt, nicht zulassen und auf später aufschieben.

Zusammenfassend überprüft das System also bei jeder Anforderung von Ressourcen, ob die Vergabe dieser Ressourcen zu einem sicheren Zustand führt. Überführt die Anforderung bei Bewilligung das System von einem sicheren wieder in einen sicheren Zustand, so werden dem anfragenden Prozess die Ressourcen zugeteilt, ansonsten wird diese Anfrage auf später verschoben und der Prozess wird zwischenzeitlich blockiert.

Der Bankier-Algorithmus wurde nun für eine einzige Art von Ressourcen, von welcher mehrere Instanzen im System existieren, erläutert. Er kann allerdings auch für verschiedene Ressourcen, wie z.B. Drucker, CD-Laufwerk, Festplatte usw. verallgemeinert werden. In diesem Fall wird bei jedem Prozess nicht nur die Anzahl an belegten und maximal angeforderten Ressourcen gespeichert, ein Skalar reicht in diesem Fall also nicht aus. Man muss sich folglich vektorieller Größen bedienen. Zu jedem Prozess muss also ein Vektor bekannt sein, der die Anzahl an belegten Ressourcen angibt. Jede Komponente des Vektors steht hierfür stellvertretend für eine Art von Ressourcen im System und der Wert, den der Vektor dabei annimmt, steht für die Anzahl dieser Art von Ressourcen, die der jeweilige Prozess belegt. Mit dem Vektor, der die maximal angeforderten Ressourcen darstellt, verhält es sich genauso. Verfügt das System über n verschiedene Art von Ressourcen, so ergeben sich daraus n -dimensionale Vektoren. Dieses Verfahren gestaltet sich mit Vektoren komplizierter, weshalb es im Rahmen dieser Arbeit nicht im Detail erläutert wird. Dabei sei auf das Werk *Moderne Betriebssysteme* von *Andrew S. Tanenbaum*, welches sich im Literaturverzeichnis unter [1] finden lässt, verwiesen.

Tabelle 2.1: Beispiel 1 eines Ressourcen-Belegungs-Zustandes.

Prozess	Anzahl belegte Ressourcen	Maximale Anzahl insgesamt benötigter Ressourcen
A	0	6
B	0	5
C	0	4
D	0	7

Tabelle 2.2: Beispiel 2 eines Ressourcen-Belegungs-Zustandes.

Prozess	Anzahl belegte Ressourcen	Maximale Anzahl insgesamt benötigter Ressourcen
A	1	6
B	1	5
C	2	4
D	4	7

2.3.1.3 Starvation (Aushungerung) [1]

Ein weiteres bekanntes Problem bei der parallelen Verarbeitung ist die **Starvation**, im Deutschen auch oft als *Aushungerung* oder *Verhungerung* bekannt. Dieser Sachverhalt ist eng mit Deadlocks verwandt, darf allerdings nicht einem Deadlock gleichgesetzt werden.

Dabei wird ein System angenommen, auf welchem mehrere Prozesse laufen, die theoretisch ständig Ressourcen anfordern können. Nun können Situationen auftreten, in welchen gleichzeitig mehrere Prozesse dieselbe Ressource anfordern. In diesem Fall muss das Betriebssystem einen Prozess nach einem bestimmten Verfahren aus der Liste von anfragenden Prozessen auswählen und diesem dann die Ressourcen zuteilen. Bei der Wahl des Auswahlverfahren ist allerdings Vorsicht geboten, da auch Verfahren, die zunächst gerecht erscheinen, dazu führen können, dass ein Prozess niemals arbeiten kann, weil er die geforderte Ressource nie erhält, obwohl er sich nicht in einem Deadlock befindet.

Ein alltägliches Beispiel wäre die Zuweisung eines Druckers an Prozesse, die ein Dokument drucken möchten. Um keinen Deadlock zu erzeugen, wählt das System immer dann, wenn mehrere Prozesse gleichzeitig den Drucker anfordern, denjenigen Prozess aus, der das kleinste Dokument

Tabelle 2.3: Beispiel 3 eines Ressourcen-Belegungs-Zustandes.

Prozess	Anzahl belegte Ressourcen	Maximale Anzahl insgesamt benötigter Ressourcen
A	1	6
B	2	5
C	2	4
D	4	7

(mit der kleinsten Dateigröße) drucken will. Dieses Auswahlkriterium scheint gerecht zu sein. Doch nimmt man eine Situation an, in welcher der Drucker ständig Aufträge von Prozessen erhält und ein Prozess eine extrem große Datei drucken möchte. Nach jedem Vollendeten Druck betrachtet das System die Warteschlange von Prozessen, wie ein Dokument drucken möchten, und wählt daraus den Prozess, der das kleinste Dokument drucken wird. Kommen nun dauernd neue, kurze Druckaufträge an, so werden diese immer vorgezogen und der Prozess, der die große Datei drucken möchte, wird niemals den Drucker zugewiesen bekommen. Unter diesen Umständen verhungert dieser Prozess, das bedeutet, dass er unendlich lange Zeit im blockierten Zustand auf die Zuteilung des Druckers warten muss, obwohl er sich nicht in einem Deadlock befindet.

Verallgemeinert kann eine Starvation immer dann auftreten, wenn an Prozesse nach einem gewissen Priorisierungs-System Ressourcen zugewiesen werden. Gibt es dann einen Prozess, der eine sehr niedrige Priorität besitzt und werden dauernd Ressourcenanfragen von Prozessen mit höheren Prioritäten gestellt, so wird der Prozess mit der sehr niedrigen Wichtigkeit unendlich lange auf die Zuteilung der Ressource warten und verhungern.

Die Aushungerung kann durch eine bereits unter Punkt Das Prozess-Modell [1] vorgestellte Strategie verhindert werden. Wird ein FCFS-Auswahlalgorithmus (*First Come - First Serve*) angewendet, so wird immer der Prozess aus der Menge von anfragenden Ressourcen ausgewählt, der am längsten wartet. Zu einem bestimmten Zeitpunkt ist jeder Prozess einmal der Prozess, der sich schon am längsten in der Warteschlange befindet, und bekommt somit die angeforderte Ressource. Somit wird eine Starvation verhindert.

2.3.2 Lösungen zu den Problemen der parallelen Verarbeitung

2.3.2.1 Lösungen zum zeitkritischen Ablauf

Betrachtet man das Problem eines zeitkritischen Ablaufes auf einer abstrakten Ebene, so müssen Mechanismen gefunden werden, um sicherzustellen, dass von mehreren Prozessen gemeinsam genutzte Ressourcen gleichzeitig nur von einem einzigen Prozess schreibend und lesend verwendet werden dürfen. Dieser Sachverhalt wird als **wechselseitiger Ausschluss**, im Englischen **Mutual Exclusion** (kurz *Mutex*) genannt, bezeichnet. Unter Verwendung dieses Verfahrens ist stets gewährleistet, dass nur ein Prozess eine gemeinsam genutzte Ressource gleichzeitig verwenden kann und alle anderen Prozesse, die auch Zugriff auf diese Ressource erhalten möchten, werden so lange blockiert, bis der Prozess die Ressource nicht mehr nutzt. Dann darf der nächste Prozess allein diese

Ressource nutzen. Das Ziel ist folglich, die Ausführung von Prozessen, die gemeinsame Ressourcen besitzen, so anzuordnen, dass mehrere Prozesse niemals gleichzeitig in ihren kritischen Bereichen sind. Wird dieses Ziel erreicht, so werden zeitkritische Abläufe vermieden. Befindet sich also ein Prozess A in seiner kritischen Region und ein Prozess B versucht ebenfalls, seine kritische Region zu betreten, so wird dieser scheitern. Der Prozess B muss vorübergehend „schlafen gelegt“ werden, bis der Prozess A seine kritische Region verlässt.

Laut Andrew S. Tanenbaum garantiert das Verhindern von zeitkritischen Abläufen allerdings noch nicht das effiziente Zusammenarbeiten mehrerer parallel ablaufenden Prozesse, die über gemeinsame Ressourcen verfügen. Laut ihm müssen die folgenden vier Bedingungen erfüllt sein, um eine hochwertige Lösung zu erzielen:

1. Mehrere Prozesse dürfen sich nie gleichzeitig in ihren kritischen Regionen, in welchen der Zugriff auf die gemeinsame Ressource erfolgt, befinden.
2. Es dürfen keine Annahmen über die Geschwindigkeit und die Anzahl der CPUs gemacht werden.
3. Kein Prozess, der sich außerhalb seiner kritischen Region befindet, darf andere Prozesse blockieren. Das bedeutet, dass ein Prozess A nur einen anderen Prozess B blockieren darf, wenn der Prozess A gerade die gemeinsame Ressource nutzt und der Prozess B sie gerne nutzen möchte.
4. Kein Prozess soll ewig darauf warten müssen, in seinen kritischen Bereich einzutreten. Somit muss die Warteschlange von Prozessen, die die gemeinsam genutzte Ressource verwendet werden, gerecht koordiniert werden.

Der gegenseitige Ausschluss unter Verwendung von kritischen Regionen ist in der Abbildung Abbildung 2.5 dargestellt. Diese Abbildung wurde dem Buch *Moderne Betriebssysteme* von *Andrew S. Tanenbaum*, welches sich im Literaturverzeichnis unter [1] finden lässt, entnommen und veranschaulicht den Vorgang grafisch.

Um diesen wechselseitigen Ausschluss zu realisieren, wurden verschiedene Mechanismen entwickelt, wobei einige im Folgenden erläutert werden. Der Grundgedanke ist jedoch immer die Schaffung eines *geregelten Zugriffs* auf die gemeinsame Ressource.

Ausschaltung von Unterbrechungen Um zu verstehen, wie diese Realisierungsmöglichkeit funktioniert, muss zunächst klargestellt wer-




Abbildung 2.5: Grafische Darstellung des wechselseitigen Ausschlusses von zwei Prozessen unter der Verwendung von kritischen Regionen.

den, wie Prozessen mitgeteilt wird, dass ihnen der Prozessor entrisen wird. Dies geschieht in der Regel durch sogenannte Interrupts, auch Unterbrechungen genannt. Durch Unterbrechungen wird die CPU also von einem Prozess zum nächsten „weitergereicht“. Die Idee besteht nun darin, die Unterbrechungen auszuschalten, sobald ein Prozess seine kritische Region betritt, und sie erst wieder einzuschalten, bevor er die Region verlässt. Durch die ausgeschalteten Unterbrechungen wird der Prozessor dem Prozess so lange ununterbrochen zur Verfügung stehen, bis er die kritische Region wieder verlässt. Somit kann der Prozess, der die kritische Region betritt, sicher sein, dass ihm kein anderer Prozess bei seinem Zugriff auf die gemeinsame Ressource stört oder in die Quere kommt.

Dieser Ansatz klingt zwar einfach, geht allerdings mit einem großen Risiko einher. Man gibt in diesem Fall einem Benutzerprozess die Macht, Unterbrechungen ein- und auszuschalten. Dies könnte von einem Prozess einfach missbraucht werden, denn schaltet er aus eigenem Antrieb die Interrupts nicht wieder ein, so bekommt nie wieder ein anderer Prozess außer er selbst die CPU.

Ein weiteres Problem ist, dass dieses Verfahren nur auf einem Ein-Prozessor-System funktioniert. Falls die *disable*-Anweisung, welche die Ausschaltung der Unterbrechungen bewirkt, auf einem Mehr-Prozessor-System mit mehr als einer CPU ausgeführt wird, so wirkt diese Anweisung nur auf der CPU, welche diese auch ausgeführt hat. Auf den anderen CPUs können die Prozesse problemlos weiterlaufen und auch auf die gemeinsame Ressource zugreifen.

Aus obigen Gründen wird klar, dass das Ausschalten der Interrupts nicht eine ideale Lösung für die Realisierung eines wechselseitigen Ausschlusses darstellt.

Sperrung durch Variablen Dieser Lösungsansatz geht von einer einzigen, gemeinsam von den um die gemeinsame Ressource konkurrierenden Prozessen zugreifbaren Sperr-Variable *lock* aus, welche mit dem Wert 0 initialisiert ist. Ist $lock = 0$, so ist die Sperre nicht gesetzt und keiner der Prozesse befindet sich gerade in seiner kritischen Region. Ist hingegen $lock = 1$, so ist die Sperre gesetzt, was bedeutet, dass sich gerade einer der Prozesse in seiner kritischen Region befindet und somit kein anderer seine kritische Region betreten darf.

Will ein Prozess in seinen kritischen Bereich eintreten, so überprüft er zunächst den Zustand der Sperr-Variablen. Ist die Sperr-Variable gleich 0, so setzt der Prozess die Variable auf 1 und betritt die kritische Region. Nach dem Verlassen der Region setzt der Prozess die Variable dann wieder auf 0, um zu signalisieren, dass sich kein Prozess aktuell in seinem kritischen Bereich befindet. Falls die Sperre beim Überprüfen jedoch gleich 1 sein würde, so würde der Prozess einfach warten, bis sie gleich 0 wird.

Leider funktioniert dieser Ansatz nicht, da auch die Variable *lock* wiederum eine gemeinsam genutzte Ressource darstellt und es deshalb auch in Zusammenhang mit dieser gemeinsam genutzten Variable zu zeitkritischen Abläufen kommen kann. Das folgende Beispiel soll das Problem dieser Lösung illustrieren. Zunächst erreicht Prozess A seine kritische Region, überprüft den Zustand der Variable *lock* und stellt fest, dass sie gleich 0 ist. Er geht also davon aus, dass kein Prozess aktuell die gemeinsame Ressource nutzt. Bevor er den kritischen Bereich jedoch für sich sperren kann, also $lock = 1$ setzen kann, wird ihm der Prozessor entrissen und der Prozess B bekommt die CPU. Auch dieser erreicht seinen kritischen Bereich und überprüft die Sperr-Variable. Diese ist immer noch auf 0, weshalb auch der Prozess B davon ausgeht, dass die gemeinsame Ressource gerade von keinem anderen Prozess verwendet wird. Jetzt setzt der Prozess B die Sperr-Variable auf 1 und betritt die kritische Region. Sobald nun der Prozess A wieder die CPU erhält, setzt dieser auch nochmals die Variable auf 1 und betritt die Region. Beide Prozesse werden nun also gleichzeitig in ihren kritischen Regionen ausgeführt, weshalb dieses Verfahren zur Realisierung von wechselseitigem Ausschluss fehlschlägt.

Um eine funktionierende Lösung zu erreichen, muss der Zugriff auf die gemeinsame Variable selbst koordiniert werden.

Test-and-Set-Anweisung Diese Lösung baut auf dem vorher genannten Konzept einer Sperr-Variable auf, löst allerdings die genannte Problematik durch Unterstützung seitens der Hardware. Viele Prozessoren haben im Befehlssatz eine Anweisung mit dem Namen

Test and Set Lock, kurz auch *Test and Set* oder *TSL* genannt. Dies ist eine Instruktion auf Maschinencode-Ebene, die im Allgemeinen die folgende Form aufweist:

TSL RX,

Dieser Befehl liest den Inhalt des Speicherwortes⁷ *LOCK* aus und speichert den ausgelesenen Wert ins Register *RX*. Anschließend speichert der Befehl einen Wert ungleich 0 an die Speicheradresse von *LOCK*.

Das Lesen und Schreiben des Speicherwortes wird dabei als garantiert hardwareseitig unteilbare, also atomare, Operation durchgeführt. Dies bedeutet, dass kein anderer Prozess auf das Speicherwort zugreifen kann, bis die Anweisung beendet ist. Des Weiteren wird während der Ausführung dieses Befehls auch der Speicherbus⁸ gesperrt. Dies bedeutet, dass auch - falls auf einem Mehr-Prozessor-System gearbeitet wird - anderen Prozessen, welche auf anderen CPUs laufen, der Zugriff auf den Speicher verwehrt bleibt, bis die Instruktion fertig abgearbeitet ist.

Nun wird wieder, wie beim Lösungsversuch *Sperrung durch Variablen* eine gemeinsame Variable *lock* verwendet, um den Zugriff auf die gemeinsam genutzte Ressource zu koordinieren. Wenn *lock* = 0 gilt, kann jeder beliebige Prozess die *TSL*-Anweisung verwenden, um die Sperr-Variable frei von zeitkritischen Abläufen auf 1 zu setzen. Dieser Prozess kann dann seinen kritischen Bereich betreten und auf die gemeinsame Ressource zugreifen. Ist die erledigt, so kann die Variable mit der gewöhnlichen Maschinencode-Instruktion *MOVE*⁹ wieder auf 0 gesetzt werden, da sich bei diesem Vorgang kein zeitkritischer Ablauf ergibt.

Auf Assembler-Ebene lassen sich nun zwei Unterprogramme *enterRegion* und *leaveRegion* schreiben. Das *enterRegion*-Unterprogramm muss dabei folgende Funktionalität unterstützen: Zunächst muss die *TSL*-Anweisung aufgerufen werden, wodurch der alte Wert der Sperr-Variable *lock* in einem Register gespeichert wird und *lock* auf 1 gesetzt. Nun wird der von der *TSL*-Anweisung in das Register gespeicherte Wert mit der Zahl 0 verglichen. Ist der Wert im Register ungleich Null, so war die Sperre bereits gesetzt und das Unterprogramm springt zurück zum Start, wodurch die Prozedur von Neuem beginnt. Sobald der Prozess, der sich gerade im

⁷Ein Datenwort, Speicherwort oder einfach nur Wort ist die Grundverarbeitungsdatengröße bei einem Computer. [27]

⁸Der Speicherbus verbindet die CPU (oder einen Speichercontroller) mit dem Hauptspeicher. [28]

⁹Der *MOVE*-Befehl kopiert einen Wert, der entweder direkt angegeben werden oder in einem Register gespeichert sein kann, in ein Register. [29]

kritischen Bereich befindet, den Bereich verlässt und die Sperr-Variable wieder auf 0 setzt, so wird auch im Register der Wert Null stehen und die Schleife, in der sich das Unterprogramm befand, beendet. Dann beendet sich das Unterprogramm mit der für den Prozess gesetzten Sperre und kehrt zum Aufrufspunkt zurück. Nun kann die kritische Region durchlaufen werden. Sobald dies geschehen ist, kann der Prozess das Unterprogramm *leaveRegion* aufrufen. In diesem wird die Sperre aufgelöst, indem einfach der Wert Null in die gemeinsame Variable *lock* gespeichert wird. Hier ist kein Aufruf der *TSL*-Anweisung nötig. Um das soeben Erklärte zu veranschaulichen, werden die beiden Unterprogramme in einer Pseudo-Assemblersprache abgefasst und im Folgenden aufgelistet.

CODE HIER EINFÜGEN

Im Unterprogramm *enterRegion* erkennt man, dass der Inhalt des Speicherwortes *LOCK* solange überprüft wird, bis eine Bedingung eintritt, in diesem Fall, dass dieser Wert gleich 0 ist. Solange *LOCK* ungleich 0 ist, wird in einer Schleife somit dauernd der Wert überprüft. Das dauernde Überprüfen einer Variable, bis sie einen gewünschten Wert annimmt, nennt man **aktives Warten**. Nun kann das vorherige Problem gelöst werden. Vor dem Betreten einer kritischen

Aktives warten soll vermieden werden.

Literaturverzeichnis

- [1] A. S. Tanenbaum, *Moderne Betriebssysteme*. Pearson Studium, 2., aktualisierte auflage ed., 2003.
- [2] B. I. GmbH, “sequentiell,” 2018.
- [3] B. I. GmbH, “parallel,” 2018.
- [4] H. Spektrum Akademischer Verlag, “Lexikon der Physik. Kausalität,” 1998.
- [5] R. Loogen, “Parallele Programmierung,” 2009.
- [6] T. Slawig, “Objektorientierte Programmierung – Grundlagen und -Begriffe,” 2004.
- [7] C. Siemers, “Prozessorgrundlagen: Von-Neumann-Architektur, Teil 3 - Phasen der Befehlsbearbeitung,” 2004.
- [8] L. Morgenstern, “Einführung in die Funktionsweise von Computersystemen,” 2017.
- [9] G. Rauber, Thomas und Rünger, *Parallel Programming for Multi-core and Cluster Systems; Second Edition*. Springer, 2013.
- [10] S. Kegel, Philipp und Gorlatch, “Grundlagen der Parallelisierung,” 2009.
- [11] B. I. GmbH, “Empirie,” 2018.
- [12] F. Beyaz, “Parallele Multiprozessorsysteme - Das Ende der Hardware Miniaturisierung?,” 2009.
- [13] Leibniz-Rechenzentrum, “SuperMUC Petascale System.”
- [14] B. Möller, “Die Teile-und-Herrsche-Strategie,” 2012.
- [15] S. Edelkamp, “Algorithmen und Datenstrukturen - Einfache Sortierverfahren.”

LITERATURVERZEICHNIS

- [16] D. Albrecht, Julia und Frey, *Sprichwörter und Psychologie - eine Annäherung*. Springer, 2017.
- [17] G. Herrtwich, Ralf und Hommel, *Nebenläufige Programme*. Springer, 1994.
- [18] C. Richter, “Einführung in Aufbau und Funktionsweise von Mikroprozessoren,” 2005.
- [19] d. f. E. Wikipedia, “Vektorprozessor.”
- [20] J. Wolf, “Linux-UNIX-Programmierung - Kapitel 10: Threads,” 2006.
- [21] d. f. E. Wikipedia, “Spooling.”
- [22] d. f. E. Wikipedia, “Deadlock (Informatik).”
- [23] d. f. E. Wikipedia, “Compiler.”
- [24] M. Bennewitz, “Systeme I: Betriebssysteme - Kapitel 6: Deadlocks,” 2013.
- [25] d. f. E. Wikipedia, “Edsger W. Dijkstra.”
- [26] d. f. E. Wikipedia, “Bankieralgorithmus.”
- [27] d. f. E. Wikipedia, “Datenwort.”
- [28] d. f. B. Wikibooks, “Computerhardware: Hauptplatine: Bus: Speicherbus.”
- [29] d. f. B. Wikibooks, “Assembler-Programmierung für x86-Prozessoren/ Befehlsreferenz.”